

Wettbewerbsarbeit

Immunregulation von T-Zellen durch Vitamin D3

Eine Netzwerkanalyse



Verfasserin:
Sofia Surace

Zürich, Dezember 2025

Experte:
Dr. Tim Roloff

Abstract

Vor dem Hintergrund potenzieller Therapieansätze für **rheumatoide Arthritis** (RA) untersucht diese Arbeit, ob Vitamin D3 (VitD3) das Verhalten von Immunzellen gezielt beeinflussen kann. Im Mittelpunkt steht die Frage, wie dendritische Zellen (DC) nach einer VitD3-Behandlung die Genregulation humaner CD14⁺-Zellen verändern. Zu diesem Zweck wurden VitD3-behandelte tolerogene DCs (VitD3-tolDCs) eingesetzt und deren Einfluss auf die Genexpression der T-Zellen analysiert. Zur Konstruktion der Genkoexpressionsnetzwerke aus RNA-Seq-Daten (GEO: **GSE128816**) wurde der Algorithmus **BC3NET** verwendet (100 Bootstraps, Estimator: Spearman). Anschliessend wurden Unterschiede zwischen Behandlungs- und Kontrollgruppe mit **DiffCoEx** identifiziert. Die Ergebnisse zeigen spezifisch veränderte Genmodule, unter anderem in der transmembranen Transportaktivität sowie in Transkriptionskomplexen. Dies zeigt mögliche Arten auf, wie VitD3 eine **antiinflammatorische Modulation** der T-Zellen verursacht und stützt die Theorie, dass VitD3 über dendritische Zellen regulierend in die Immunantwort eingreifen kann. Trotz nicht RA-spezifischer Datensets liefert die Analyse Hypothesen, die im Folgenden experimentell und bioinformatisch überprüft werden könnten.

Die folgende Github-Repository enthält ein PDF der Arbeit, den verwendeten Code und das Datenset sowie alle erhaltenen Ergebnisse:

https://github.com/py-sofia/Maturaarbeit_Sofia-Surace_2025

Inhaltsverzeichnis

Begriffsverzeichnis	v
Vorwort	1
1 Einleitung	2
2 Theoretische Grundlagen	3
2.1 Immunologie	3
2.1.1 Dendritische Zellen: die Dirigenten der Immunantwort	3
2.1.2 T-Zellen und die Balance zwischen Angriff und Toleranz	6
2.1.3 Autoimmunerkrankungen und Rheumatoide Arthritis	6
2.1.4 Pathologische Prozesse im Gelenk eines RA-Patienten	7
2.2 Genetik	8
2.2.1 Was ist ein Gen?	8
2.2.2 Messung der Genexpression	9
2.3 Bioinformatik: Gennetzwerke	10
2.3.1 Was ist ein Gennetzwerk?	10
2.3.2 Arten von Netzwerken	12
2.3.3 Umwandlung in Matrizen	12
2.3.4 Die skalenfreie Topologie	13
2.3.5 Permutationstests	14
2.4 Mathematik und Statistik	15
2.4.1 Der Spearman-Korrelationskoeffizient	15
2.4.2 Mutual Information	15
2.4.3 Weitere Grundlagen der Statistik	16
3 Methodik	17
3.1 Daten	17
3.1.1 Generierung und Charakterisierung des Datensets	17
3.1.2 Normalisierung	18
3.2 Materialien und Software	18
3.3 Netzwerkerstellung mit BC3NET	18
3.3.1 Erstellung eines Bootstrap-Ensembles (Bagging)	19
3.3.2 Netzwerkinferenz mit C3NET für jeden Bootstrap-Datensatz	20
3.3.3 Aggregation und statistische Validierung	21
3.3.4 Praktische Umsetzung	22
3.4 Skalenfreie Topologie und der Parameter β_{a1}	22

3.5	Grobe Netzwerkbeschreibung	24
3.6	DiffCoEx	25
3.6.1	Adjazenzmatrizen als Ausgangslage	26
3.6.2	Berechnung der Adjazenzdifferenz-Matrix	26
3.6.3	Topologischer Overlap zur Identifikation gemeinsamer Muster	27
3.6.4	Clustering und Modul-Identifikation	27
3.6.5	Statistische Signifikanzprüfung	28
3.7	Genset-Analyse	29
3.7.1	Gene Ontology (GO)	29
3.7.2	Praktische Umsetzung	30
3.8	Vergleich mit anderen Datensets	30
4	Ergebnisse	32
4.1	Normalisierung	32
4.2	BC3NET-Netzwerke	33
4.3	Skalenfreie Topologie	33
4.4	Wahl des Parameters cutHeight	35
4.5	Identifizierte differentiell koexprimierte Module	36
4.6	Überrepräsentierte Signalwege	37
4.7	Permutationstest	38
4.8	Vergleich mit weiteren Datensets	40
5	Diskussion	41
5.1	Die Wahl des Datensets	41
5.2	Die Bedeutung von DiffCoEx	42
5.3	Biologische Interpretation der gefunden Pathways	43
5.3.1	Transkriptionelle Prozesse	43
5.3.2	Immunmetabolismus	43
5.3.3	Der Bezug zu Rheumatoider Arthritis	44
5.4	Methodische Überlegungen und Schwächen	44
5.4.1	Skalenfreie Topologie und der Parameter beta1	44
5.4.2	Transformation und Verteilungsproblematik	45
5.4.3	Normalisierung	45
5.4.4	Die Wahl der Schnitthöhe im hierarchischen Clustering	45
5.4.5	Der Vergleich mit weiteren Datensets	46
5.5	Vergleichbarkeit und Reproduzierbarkeit	46
5.6	Ausblick	47
6	Fazit	48
	Beiträge	49
	Verwendung generativer KI	50

Anhang	62
Over-Representation Analysis (ORA)	62
Begründung der Estimatorwahl “Spearman” für BC3NET	62
Korrektur für multiples Testen	63
Der Topological Overlap Measure (TOM)	64

Begriffsverzeichnis

APC antigenpräsentierende Zelle 3, 4

BC3NET Bagging C3NET 2, 18–24, 26, 33, 42, 45–48, 59, 61

BH-Korrektur Benjamini-Hochberg-Korrektur 29

BP Biological Process 30

C3NET C3NET 20

CC Cellular Component 30

DC dendritische Zelle 3, 4, 6, 17, 47

DiffCoEx Differentially CoExpressed gene modules 2, 25, 26, 59

FACS Fluoreszenz-aktivierte Zellsortierung 17

GCN Genkoexpressionsnetzwerk 12

GEO Gene Expression Omnibus 17

GM-CSF Granulozyten-Makrophagen-Kolonie-stimulierende Faktor 17

GO Gene Ontology 29, 30, 37, 40, 60

GRN Genregulatorisches Netzwerk 12

H₀ Nullhypothese 16

IL Interleukin 4–6, 8, 17

IMID Immune-Mediated Inflammatory Disease 6

mDC immunogene dendritische Zelle 2, 6, 17

MF Molecular Function 30

MI Mutual Information 15, 20

ORA Over-Representation Analysis 2, 29

RA rheumatoide Arthritis 6, 7, 41–44, 47, 48

RIN RNA-Integritätswert 17

T_{reg} regulatorische T-Zelle 2, 5, 41, 43, 44

TNF- α Tumornekrosefaktor- α 6, 8, 9, 17

tolDC tolerogene dendritische Zelle 2, 6, 17, 41

TOM Topological Overlap Measure 26, 27, 33, 36

TRN transkriptionsregulatorisches Netzwerk 12

TT Tetanus-Toxin 17

VEGF Vascular Endothelial Growth Factor 7, 37

VitD3 Vitamin D3 1, 2, 4, 5, 17, 37, 41, 48

WGCNA Weighted Gene Co-expression Network Analysis 14, 19, 25

Vorwort

Mein Interesse an der Medizin, insbesondere an Autoimmunerkrankungen, ist persönlich motiviert. Die rheumatoide Arthritis meiner Mutter und die Debatte um komplementäre Therapieansätze rückten Vitamin D3 in meinen Fokus. Diese Arbeit entsprang dem Wunsch, dessen vieldiskutierte, aber oft unklare Wirkung wissenschaftlich fundiert zu untersuchen. Da mir im Rahmen einer Maturaarbeit die Mittel für experimentelle Laborforschung fehlten, wählte ich einen bioinformatischen Ansatz. Ziel war es, meine Programmierkenntnisse zu nutzen, um die potenziellen Effekte von **VitD3** auf Genexpression zu modellieren und zu analysieren.

Die Einarbeitung in die komplexe Methodik der Netzwerkanalyse war herausfordernd. Umso dankbarer bin ich für die Hilfe, die ich erhalten habe:

Ich möchte mich bei Prof. Dr. Dr. Caroline Ospelt bedanken, die mir einen wissenschaftlich fundierten Weg für die Analyse aufzeigte, sowie bei Prof. Dr. Amedeo Caflisch für den Einblick in verschiedene Ansätze der biologischen Simulation. Dr. Patrick Aschwanden, Chemie- und Informatiklehrer an der Kantonsschule Zürich Nord, erwies sich als hilfreicher und motivierter Betreuer für meine Arbeit. Ebenso danke ich Prof. Dr. Mark Robinson, der als Korreferent bei der Präsentation an der Schule unterstützte. Ein besonderer Dank gebührt Dr. Izaskun Mallona Gonzalez. Sie war meine wichtigste Stütze während der anspruchsvollen Erstellung und Analyse der Netzwerke. Ihre Bereitschaft, die Stärken und Schwächen der Methodik offen zu diskutieren, sowie unsere intellektuell anregenden Gespräche waren für das Gelingen dieser Arbeit von unschätzbarem Wert. Im Rahmen des Nationalen Wettbewerbs von Schweizer Jugend forscht erhielt ich zudem wertvolle Unterstützung von meinem Experten Dr. Tim Roloff; seinen Anregungen und Korrekturen ist das heutige Niveau meiner Arbeit zu verdanken.

1 Einleitung

Das menschliche Immunsystem muss pathogenbedingte Bedrohungen neutralisieren und gleichzeitig körpereigene Strukturen tolerieren. Eine Störung dieses Gleichgewichts kann zu Autoimmunerkrankungen wie Multipler Sklerose oder rheumatoide Arthritis führen. Die Erforschung von zellulären und molekularen Mechanismen, die **immunologische Toleranz** fördern, ist daher von zentraler Bedeutung.

Dendritische Zellen steuern die Aktivierung und Differenzierung von T-Zellen und können entzündungsfördernde oder -hemmende Signale vermitteln. Unter Einfluss von **VitD3** lassen sich **tolerogene dendritische Zellen (tolDCs)** erzeugen, die **T_{reg}S** induzieren und somit entzündungshemmende Prozesse fördern. Obwohl die **immunsuppressiven** Effekte von **VitD3** vielfach beschrieben wurden, werden die zugrunde liegenden Signalwege zwischen **tolDCs** und naiven T-Helferzellen (CD4⁺-T-Zellen) noch unzureichend verstanden.

Moderne Transkriptom- und Netzwerkmethoden ermöglichen es, Genregulationsmechanismen systematisch zu analysieren. Koexpressionsnetzwerke erlauben Rückschlüsse auf **funktionell verwandte Gene**, während differenzielle Koexpressionsanalysen Veränderungen zwischen experimentellen Bedingungen sichtbar machen. Dadurch können modulare Strukturen identifiziert werden, die auf **zentrale Signalwege** oder regulatorische Knotenpunkte hinweisen. Da aus Rechenzeitgründen keine permutationsbasierte Signifikanzprüfung durchgeführt werden konnte, sind die Ergebnisse als **explorativ** zu betrachten. Dennoch soll die Analyse dazu beitragen, Hypothesen über immunmodulatorische Prozesse und potenzielle Zielgene zu generieren, die in zukünftigen Studien experimentell überprüft werden können. Diese Arbeit verfolgt drei Ziele:

1. Erstellung eines Genkoexpressionsnetzwerks für T-Zellen, die mit **VitD3**-behandelten **tolDC** (**VitD3-tolDCs**) oder mit reifen **mDCs** ko-kultiviert wurden (**BC3NET**).
2. Identifikation von Modulen, die ihre Koexpression auf ähnliche Art ändern (**DiffCoEx**).
3. Funktionelle Einordnung der Module im Kontext immunologischer Toleranzmechanismen (**ORA**).

Kapitel 2 beschreibt die biologischen und methodischen Grundlagen. Kapitel 3 erläutert Datensatz und Analyseverfahren. Kapitel 4 präsentiert die Ergebnisse, Kapitel 5 diskutiert sie im Forschungskontext und benennt Limitationen. Kapitel 6 fasst die wichtigsten Erkenntnisse zusammen und skizziert weitere Forschungsansätze.

2 Theoretische Grundlagen

2.1 Immunologie

Das Immunsystem ist das biologische Abwehrsystem des Körpers, das ihn vor schädlichen Einflüssen wie krankheitserregenden Mikroorganismen (Pathogenen) und abnormalen körpereigenen Zellen, beispielsweise Tumorzellen, schützt [1], [2]. Seine Hauptaufgabe ist es, die Unversehrtheit des Organismus zu gewährleisten. Man unterscheidet grundsätzlich zwischen zwei eng miteinander verknüpften Armen des Immunsystems: dem angeborenen und dem erworbenen (oder adaptiven) Immunsystem.

- Das **angeborene Immunsystem** agiert als erste Verteidigungslinie. Es reagiert sofort und unspezifisch¹ auf eine Bedrohung, kann aber keine langanhaltende Immunität aufbauen.
- Das **adaptive Immunsystem** reagiert langsamer, dafür aber hochspezifisch auf bestimmte Erreger. Eine seiner wichtigsten Eigenschaften ist die Fähigkeit, ein immunologisches Gedächtnis zu bilden, was bei einem erneuten Kontakt mit demselben Pathogen eine schnellere und stärkere Abwehrreaktion ermöglicht.

Alle Zellen, die an diesen Abwehrprozessen beteiligt sind, haben einen gemeinsamen Ursprung: die blutbildenden (hämatopoetischen) Stammzellen im Knochenmark. Diese Stammzellen entwickeln sich entlang zweier Hauptlinien weiter (Abb. 1): der myeloischen und der lymphatischen Linie. Aus der **lymphatischen Vorläuferzelle** entstehen unter anderem die B- und T-Lymphozyten (B- und T-Zellen), welche die zentralen Akteure des adaptiven Immunsystems sind. Aus der **myeloischen Vorläuferzelle** gehen unter anderem Monozyten, Granulozyten und dendritische Zellen (Fresszellen) hervor, die wichtige Funktionen im angeborenen Immunsystem übernehmen.

2.1.1 Dendritische Zellen: die Dirigenten der Immunantwort

Eine besondere Rolle im Immunsystem nehmen die sogenannten **antigenpräsentierenden Zellen (APCs)** ein. Zu ihnen gehören Makrophagen, B-Lymphozyten und insbesondere die dendritischen Zellen (**DCs**). Sie fungieren als Brücke zwischen der angeborenen und der adaptiven Immunantwort. Ihre Aufgabe ist es, Pathogene aufzunehmen, sie in kleinere Stücke (**Antigene**) zu zerlegen und diese Antigene den Zellen des adaptiven Immunsystems – vor allem den T-Zellen – zu präsentieren.

¹In diesem Kontext bedeutet unspezifisch, dass es gegen jede erkannte Bedrohung vorgeht und sich z.B. nicht auf einen bestimmten Erreger spezialisiert hat.




Abbildung 1: Stammbaum der Leukozyten. Aus Stammzellen im Knochenmark können sich entweder lymphatisch Lymphocyten oder myeloisch verschiedene Fresszellen entwickeln. Quelle: [2]

DCs gelten als die effektivsten APCs. Man findet sie zunächst in einem unreifen Zustand in verschiedenen Geweben des Körpers, wo sie auf potenzielle Gefahren, wie beispielsweise Tumorzellen oder Pathogene, lauern. Treffen diese **unreifen dendritischen Zellen** (iDCs) auf Gefahrensignale, wie sie von Bakterien oder geschädigten Körperzellen ausgehen, beginnen sie zu reifen.

Dieser Reifungsprozess führt zu zwei grundlegend unterschiedlichen Typen von DCs, die die nachfolgende Immunreaktion in gegensätzliche Richtungen lenken (Abb. 2):

- **Reife, immunogene dendritische Zellen (mDC):** Dies ist der "Standardweg" bei einer Infektion. Die reifende Zelle exprimiert vermehrt Moleküle an ihrer Oberfläche, die für die Aktivierung von T-Zellen notwendig sind (z.B. CD80, CD86, MHC-II). Sie wandert in die nächstgelegenen Lymphknoten und schüttet **pro-inflammatorische** (entzündungsfördernde) Botenstoffe wie das Zytokin Interleukin-12 (**IL-12**) aus. Dort aktivieren diese Zytokine naive (inaktive) T-Zellen und lösen so eine starke, auf Angriff ausgerichtete Immunantwort aus.
- **Tolerogene dendritische Zelle (tolDC):** Unter dem Einfluss bestimmter Substanzen entwickeln sich aus unreifen DCs keine immunogene, sondern tolerogene Zellen. Zu diesen Substanzen gehören unter anderem **VitD3** [3], Vitamin A und das Zytokin TGF- β . Tolerogene DCs zeichnen sich dadurch aus, dass sie nur wenige der aktivierenden Oberflächenmoleküle tragen und stattdessen **anti-inflammatorische** (entzündungshemmende) Zytokine wie **IL-10** produzieren. Ihre Hauptfunktion besteht nicht darin, eine Abwehrreaktion auszulösen, sondern diese gezielt zu unterdrücken. Dadurch verhindern sie, dass das Immunsystem in gesundem Gewebe unnötig oder gegen harmlose körpereigene Strukturen reagiert.




Abbildung 2: Einfluss dendritischer Zellen auf die T-Zell-Differenzierung [1], abgeänderte Abbildung. Reife DCs sezernieren u.a. das pro-inflammatorische Zytokin **IL-12**, welches die Differenzierung von inflammatorisch wirkenden TH1-Zellen begünstigt. Durch den Einfluss von TGF- β , Retinsäure oder **VitD3** können aus unreifen DCs tolerogene DCs entstehen, die vor allem über die Sekretion des antiinflammatorischen **IL-10** die Differenzierung von **T_{reg}**-sowie TH2-Zellen induzieren.

2.1.2 T-Zellen und die Balance zwischen Angriff und Toleranz

Naive T-Helferzellen ($CD4^+$ -T-Zellen) sind die zentralen Schaltstellen der adaptiven Immunantwort. Je nachdem, welche Signale sie von einer **DC** erhalten, entwickeln sie sich in unterschiedliche Subpopulationen mit spezialisierten Aufgaben. Für das Verständnis von Autoimmunerkrankungen und deren potenzieller Behandlung sind vor allem zwei Entwicklungspfade von Bedeutung:

Der **pro-inflammatorische Pfad**: Präsentiert eine **mDC** ein Antigen und schüttet dabei **IL-12** aus, differenziert die naive T-Zelle zu einer **T-Helferzelle** vom Typ 1 (TH1). TH1-Zellen koordinieren eine aggressive Immunantwort, indem sie selbst **entzündungsfördernde Zytokine** wie Interferon- γ (IFN- γ) und **TNF- α** produzieren, die zur Eliminierung von Pathogenen oder infizierten Zellen beitragen. Bei Autoimmunerkrankungen wie der Rheumatoiden Arthritis ist dieser Pfad überaktiv und richtet sich fälschlicherweise gegen körpereigenes Gewebe.

Der **anti-inflammatorische Pfad**: Präsentiert hingegen eine **tolDC** ein Antigen und schüttet dabei **IL-10** aus, wird die Entwicklung der naiven T-Zelle in eine gänzlich andere Richtung gelenkt. Aus ihr entsteht eine **regulatorische T-Zelle**. Diese Zellen spielen eine zentrale Rolle bei der Unterdrückung fehlgeleiteter Immunreaktionen und **verhindern damit Autoimmunität**, also Angriffe des Immunsystems auf körpereigenes Gewebe. Sie sichern diese **Selbsttoleranz**, indem sie selbst die anti-inflammatorischen Zytokine **IL-10** und TGF- β freisetzen und die Aktivität anderer Immunzellen, einschliesslich der TH1-Zellen, dämpfen.

2.1.3 Autoimmunerkrankungen und Rheumatoide Arthritis

Während ein ausbalanciertes Immunsystem zwischen schädlichen und körpereigenen Strukturen unterscheiden kann, ist diese Fähigkeit bei **Autoimmunerkrankungen** gestört. Die rheumatoide Arthritis (**RA**) ist ein Beispiel für eine solche **immunvermittelte entzündliche Erkrankung** (Immune-Mediated Inflammatory Disease oder **IMID**): Hier verschiebt sich das im vorigen Kapitel beschriebene Gleichgewicht von einer kontrollierten, toleranten Immunantwort hin zu einem selbsterhaltenden, pro-inflammatorischen Zustand, der sich fälschlicherweise **gegen den eigenen Körper** richtet.

RA ist eine systemische Autoimmunerkrankung, die sich vor allem durch die **Entzündung der Gelenkinnenhaut** (Synovium) auszeichnet. Dies führt zu den charakteristischen Symptomen wie Schmerzen, Schwellungen und Steifheit in den Gelenken, insbesondere in Händen, Füßen und Knien. Unbehandelt schreitet die Entzündung fort und führt zur **unumkehrbaren Zerstörung** von Knorpel und Knochen, was in Deformitäten und starker funktioneller Beeinträchtigung resultiert. Obwohl die genauen Auslöser der **RA** noch nicht vollständig geklärt sind, geht man von einem Zusammenspiel aus genetischer Veranlagung und umweltbedingten Faktoren aus.

2.1.4 Pathologische Prozesse im Gelenk eines RA-Patienten

Im gesunden Zustand ist das **Synovium** eine dünne Zellschicht, die das Gelenk auskleidet, den Knorpel mit Nährstoffen versorgt und Gelenkschmiere² produziert [4]. Bei der Rheumatoiden Arthritis verändert sich diese Struktur durch folgende Prozesse dramatisch (Abb. 3) [5]:




Abbildung 3: Gesundes vs. RA-Gelenk, abgeänderte Abbildung [6]. Bei RA wird durch eine Immunzell-Infiltration eine Hyperplasie der Gelenkinnenhaut ausgelöst und es bildet sich ein Pannus. Verstärkte Angiogenese zur Erhaltung der vergrößerten Zellmasse ist beobachtbar.

- **Infiltration von Immunzellen:** Das Synovium wird von einer grossen Anzahl an Immunzellen, darunter T-Zellen, B-Zellen und Makrophagen, überschwemmt. Zur Erhaltung der vergrößerten inflammatorischen Zellmasse werden neue Blutgefäße gebildet (**Angiogenese**). Diese versorgen die Immunzellen mit Sauerstoff und Nährstoffen und ermöglichen so das Fortschreiten der Entzündung [7], [8]. Dabei wirkt vor allem der vaskuläre endotheliale Wachstumsfaktor (**VEGF**) mit. **VEGF-Serumkonzentrationen**³ sind bei RA-Patienten erhöht und korrelieren direkt mit der **Krankheitsaktivität** [8].
- **Pannusbildung:** Durch die chronische Entzündung verdickt sich die Gelenkinnenhaut stark (**Hyperplasie**) und beginnt, tumorartig in den Gelenkknorpel und den angrenzenden Knochen hineinzuwachsen. Dieses wuchernde, aggressive Gewebe wird als **Pannus** bezeichnet.

²Gelenkschmiere ist eine Flüssigkeit, welche der Verringerung des Reibungswiderstandes dient.

³Mit "Serumkonzentration" ist die Konzentration im Blutserum gemeint.

- **Gewebezerstörung:** Die im Pannus aktiven Zellen setzen durch die Freisetzung von **pro-inflammatorischen Zytokinen** wie **TNF- α** , **IL-1** und **IL-6** eine Kaskade zerstörerischer Prozesse in Gang. Beispielsweise regen diese Zytokine Knorpelzellen (Chondrozyten) und Bindegewebszellen (synoviale Fibroblasten) [9] an, Enzyme freizusetzen, die den **Knorpel abbauen** (z.B. Kollagenasen). Gleichzeitig fördern sie die Aktivierung von Osteoklasten, spezialisierten Zellen, die für den **Abbau von Knochengewebe** verantwortlich sind.

2.2 Genetik

2.2.1 Was ist ein Gen?




Abbildung 4: Vom Gen zum Genprodukt [10] Die Herstellung von Proteinen folgt einem mehrstufigen Prozess. Bei jedem Schritt sind mehrere epigenetische Faktoren beteiligt, welche das Produkt verändern können.

In der Desoxyribonukleinsäure (DNA) sind alle Erbinformationen eines Organismus gespeichert. Bestimmte Abschnitte der DNA werden **Gene** genannt [10], [11]. Sie dienen

als “Bauanleitungen” für Proteine, welche die Grundlage biologischer Systeme bilden. Die Bildung eines Genprodukts wird **Expression** genannt und erfolgt über mehrere Schritte. Zunächst wird das Gen in einem Prozess namens **Transkription** “abgelesen”: Dabei wird mithilfe des RNA-Polymerase-Enzyms eine Arbeitskopie des Gens in Form von messenger-RNA (mRNA) erstellt. Anschliessend wird die mRNA in der **Translation** als Vorlage für die Herstellung von Proteinen genutzt.

Die Expression eines Gens geschieht nicht zufällig, sondern wird durch ein komplexes Zusammenspiel von **regulatorischen Elementen** auf der DNA und speziellen Proteinen, den **Transkriptionsfaktoren**, exakt gesteuert (Abb. 4). Diese Steuerung ist die Basis für genbasierte Netzwerke, da die Expression eines Gens von innerlichen und äusserlichen Faktoren beeinflusst wird. Für eine Entzündung beispielsweise werden mehr pro-inflammatorische Zytokine (z.B. **TNF- α**) benötigt. Die dafür kodierenden Gene sind also stärker exprimiert [12].

Da die Quantifizierung der Proteinkonzentrationen oft schwierig ist, misst man in der Forschung jedoch zumeist die mRNA – die bereits transkribierte, jedoch noch nicht translatierte Protein-Vorstufe [13], [14]. Die Gesamtheit aller RNA-Transkripte in einer Zelle zu einem bestimmten Zeitpunkt wird als **Transkriptom** bezeichnet und gibt einen Einblick in die zelluläre Aktivität [15].

2.2.2 Messung der Genexpression

Um genregulatorische Netzwerke zu analysieren, muss die Aktivität von Tausenden von Genen gleichzeitig gemessen werden [14], [15]. Die Daten werden typischerweise mit einer der folgenden Methoden erzeugt:

- **DNA-Microarrays:** Bei dieser Methode werden kurze, bekannte DNA-Sonden⁴ [16] auf einem Chip fixiert. Die Menge der gebundenen RNA an einer bestimmten Sonde ist proportional zur Expression des entsprechenden Gens und wird über ein Fluoreszenzsignal gemessen.
- **RNA-Sequencing (RNA-Seq):** Diese Methode sequenziert die RNA-Moleküle einer Probe direkt und zählt sie. Sie bietet eine höhere Genauigkeit und einen grösseren dynamischen Bereich als Microarrays und kann auch bisher unbekannte Transkripte entdecken.

Beide Technologien liefern riesige Datensätze, die zeigen, welche Gene in einer Zelle unter bestimmten Bedingungen “an-” oder “ausgeschaltet” sind. Die wahre Schwierigkeit liegt in der Analyse und Interpretation dieser Daten.

⁴Eine DNA-Sonde ist ein DNA-Molekül, das eine komplementäre Basensequenz zum gesuchten Gen aufweist.

2.3 Bioinformatik: Gennetzwerke

2.3.1 Was ist ein Gennetzwerk?

Gennetzwerke sind eine Art, die Expression von Genen zu quantifizieren und zu vergleichen. Einige Begriffe aus der Graphentheorie sind in diesem Kontext relevant (siehe Tab. 1) [14]:

Tabelle 1: Definitionen zentraler Begriffe der Netzwerkanalyse.

Begriff	Anwendung
Knoten	Ein einzelnes Gen.
Kante	Die mathematische Verwandtschaft zwischen zwei Genen.
Topologie	Die Struktur eines Netzwerks.
Nachbarn	Gene, welche durch eine Kante verbunden sind.
Grad eines Knotens	Die Gesamtanzahl der Nachbarn.
Dichte	Verhältnis der vorhandenen Kanten zu den möglichen Kanten in einem Netzwerk [17].
Durchmesser	Längster kürzester Weg zwischen zwei Knoten [17].
Modul / Cluster	Eine Gruppe von verwandten Genen.

Da meistens mehrere Gene an der Herstellung eines Proteins und immer eine Vielzahl von Genen in komplexeren biologischen Prozessen beteiligt ist, lassen sich aus den einzelnen Strukturen biologisch relevante Netzwerke erstellen (Abb. 5).

Die Kanten können sich dabei nur durch ihre Anwesenheit auszeichnen (Abb. 6a), gerichtet sein (Abb. 6b) oder eine Gewichtung haben (Abb. 6c). Kombinationen sind möglich. Gewichtete Kanten stellen meistens die statistische Ähnlichkeit im Expressionsmuster (Koexpression) als Verbindungsstärke zwischen zwei Genen dar.




Abbildung 5: Schematische Darstellung eines genregulatorischen Netzwerks [14]. Ein komplexes biophysisches Modell beschreibt die Interaktion zwischen drei Genen: direkte Regulation (Gen 2 durch Gen 1) sowie kombinatorische Regulation durch eine Komplexbildung (Gen 3 durch die Gene 1 und 2). Das gerichtete Netzwerk stellt die abstrahierte Struktur des Systems dar.




Abbildung 6: Verschiedene Kantenarten [14], abgeänderte Abbildung. 6a) zeigt ein Netzwerk mit ungerichteten, ungewichteten Kanten. b) hat gerichtete Kanten (Pfeile) und c) hat gewichtete Kanten (erkennbar an der Stärke der Verbindungslinien).

2.3.2 Arten von Netzwerken

Grob lassen sich die genbasierten Netzwerke in drei Kategorien einteilen [18] (Abb. 7):

- A **Genkoexpressionsnetzwerke (GCNs)** haben ungerichtete, aber gewichtete Kanten und können infolgedessen auch die kausalen Zusammenhänge nicht wiedergeben. Sie kommen bei der Suche nach **funktional verwandten Genen** zum Einsatz.
- B **Genregulatorische Netzwerke (GRNs)** zeichnen sich dadurch aus, dass all ihre Kanten gerichtet sind. Sie geben Ausschluss darüber, welche Gene sich gegenseitig **regulieren**⁵.
- C Eine Unterkategorie von **GRNs** sind die **transkriptionsregulatorischen Netzwerke**. Deren gerichtete Kanten gehen von Transkriptionsfaktor-Genen aus.

Allerdings wird in der Forschung diese Einteilung nur lose verwendet. Die Bezeichnung “genregulatorisches Netzwerk” hat sich als Oberbegriff zu allen Netzwerken etabliert und wird teilweise auch für **GCNs** oder **TRNs** verwendet. Da in dieser Arbeit jedoch die Koexpression untersucht wird, wird der Ausdruck “Koexpressionsnetzwerk” (**GCN**) verwendet werden.




Abbildung 7: Arten von Gennetzwerken [18]. Das Koexpressionsnetzwerk (**GCN**) in A) stellt die Koexpression zwischen jeweils zwei Genen mittels einer Linie (Kante) dar. B): Genregulatorische Netzwerke (**GRNs**) hingegen zeigen, welches Gen i ein anderes Gen j beeinflusst (reguliert). **TRNs** wie das in C) zeigen, welche Gene durch die Herstellung von Transkriptionsfaktoren andere Gene beeinflussen.

2.3.3 Umwandlung in Matrizen

Häufig sind Netzwerke für weitere Berechnungen ungeeignet und werden daher als **Adjazenzmatrizen** dargestellt. Zeilen und Spalten entsprechen den Knoten, die

⁵“Regulieren” bedeutet beispielsweise, dass Gen A ein Protein P_A herstellt, dass die Transkription von Gen B verhindert. Gleichzeitig kann P_A dafür verantwortlich sein, die Translation von Gen B zu fördern. Vergleiche Abb. 5.

numerischen Einträge den Kanten [19]; deren Werte variieren je nach Netzwerktyp (Abb. 8). Die Matrix ist symmetrisch, und die Diagonale wird auf null gesetzt.




Abbildung 8: Graphen nach Kantenart und ihre Adjazenzmatrizen [19]. In ungerichteten, ungewichteten Netzwerken werden die Kanten mit 1 (vorhanden) oder 0 (nicht vorhanden) angegeben. Adjazenzmatrizen von gerichteten Netzwerken zeigen nur eingehende Kanten an. Für gewichtete Netzwerke liegen die Kantenwerte in einem bestimmten Bereich, bspw. [0; 100] oder [0; 1].

2.3.4 Die skalenfreie Topologie

Ein zentrales Kriterium zur **Validierung** von biologischen Netzwerken ist die Untersuchung ihrer globalen Struktur [20], [21], [22].

Eine skalenfreie Topologie (**scale-free topology**) ist ein fundamentales Merkmal vieler realer Netzwerke, einschliesslich biologischer Systeme. Solche Netzwerke zeichnen sich dadurch aus, dass die meisten Knoten (Gene) nur wenige Verbindungen aufweisen, während einige wenige Knoten, sogenannte **“Hubs”**, eine extrem hohe Anzahl von Verbindungen besitzen. Die Wahrscheinlichkeit $P(k)$, einen Knoten mit k Verbindungen (Kanten) zu anderen Knoten zu finden, ist gegeben durch das Potenzgesetz $P(k) \sim k^{-\gamma}$ (Abb. 9). Der Parameter γ liegt im Normalfall im Intervall (2; 3).

Die biologische Relevanz dieser Topologie ist signifikant. Metabolische und regulatorische Netzwerke folgen oft diesem Prinzip [23], [24]. Es wird angenommen, dass diese




Abbildung 9: Optimale Gradverteilung. Jeder Punkt in diesem Graphen stellt die Wahrscheinlichkeit $P(k)$ dar, einen Knoten mit k Kanten zu finden. Für skalenfreie Netzwerke ergibt sich dadurch eine abfallende Gerade, an deren Ende sich eine Häufung von Punkten befinden kann. (By Rsoaresp - Own work, CC BY-SA 4.0, <https://commons.wikimedia.org/w/index.php?curid=34204143>)

Architektur ein grundlegendes Designprinzip zellulärer Organisation widerspiegelt, das den Systemen eine hohe **Robustheit** gegenüber zufälligen Störungen und Fehlern verleiht. Parameter, die zu einer schlechten Anpassung an die skalenfreie Topologie führen, korrelieren oft mit einem **schwächeren “biologischen Signal”** (z.B. einer geringeren Korrelation zwischen Konnektivität und funktioneller Aussagekraft).

Aufgrund dieser starken biologischen Evidenz wird das Erreichen einer skalenfreien Topologie oft als **Qualitätskriterium** für die Netzwerk-Konstruktion verwendet. Methoden wie **WGCNA** nutzen dieses Kriterium (gemessen als R^2 -Wert), um die Parameter für die Erstellung der Adjazenzmatrix zu optimieren.

2.3.5 Permutationstests

Eine weitere Art, die Qualität und statistische Aussagekraft eines Netzwerks zu überprüfen, ist ein sogenannter **Permutationstest**. Im Folgenden wird die von Tesson et al. (2010) beschriebene Anwendung vorgestellt [25].

Zunächst wird ein Dispersionswert berechnet: Dieser misst, wie sehr sich Korrelation zwischen zwei Genen aus den Modulen $c1$ und $c2$ der Test- und Kontrollbedingung unterscheidet. Falls $c1 = c2$, quantifiziert der Dispersionswert die Koexpressionsunterschiede innerhalb von $c1$. Anschliessend werden alle Proben 1000-mal **zufällig in zwei Gruppen** aufgeteilt, um gewissermassen eine neue “Test”- und “Kontrollgruppe” zu erstellen, und es wird für jede Zuteilung ein Dispersionswert berechnet. Die dadurch

entstehende Verteilung zeigt an, wie gross die zufällig zu erwartenden Unterschiede wären. Dagegen vergleicht man den tatsächlich beobachteten Dispersionswert.

2.4 Mathematik und Statistik

Für **normale** Datenverteilungen kann zur Berechnung des Verwandtschaftsgrades zweier Gene mittels des Estimators “Spearman” die gegenseitige Information berechnet werden [26].

2.4.1 Der Spearman-Korrelationskoeffizient

Der Spearman-Korrelationskoeffizient untersucht, ob zwischen zwei Variablen ein **monotoner Zusammenhang** besteht. “Monoton” bedeutet, dass grössere Werte der einen Variable im Allgemeinen mit grösseren (oder kleineren) Werten der zweiten Variable einhergehen. Dabei muss der Zusammenhang **nicht linear** sein [27].

Im Gegensatz zur Pearson-Korrelation, die direkt mit den ursprünglichen Messwerten arbeitet, basiert die Spearman-Korrelation auf **Rängen**: Alle Werte werden der Grösse nach sortiert, und jeder Beobachtung wird eine **Rangnummer**⁶ zugeordnet. Bei gleichen Werten erhalten diese entweder den gleichen Rang oder den Mittelwert der entsprechenden Rangpositionen [28]. Anschliessend wird auf diesen Rangwerten die Pearson-Korrelation berechnet. Die Formel für die Pearson-Korrelation lautet [29], [30]:

$$\rho_{x,y} = \frac{\sum_i (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_i (x_i - \bar{x})^2} \cdot \sqrt{\sum_i (y_i - \bar{y})^2}}$$

Dabei bezeichnen x_i und y_i die einzelnen Messwerte (hier: die Ränge) und $\bar{x}$ sowie $\bar{y}$ deren Mittelwerte. Die Terme $\sqrt{\sum_i (x_i - \bar{x})^2}$ bzw. $\sqrt{\sum_i (y_i - \bar{y})^2}$ entsprechen den jeweiligen Standardabweichungen der Rangwerte.

Da Spearman nicht mit den ursprünglichen Messwerten, sondern mit deren Rängen arbeitet, handelt es sich um ein **nicht-parametrisches Verfahren**. Das bedeutet, dass keine bestimmte Verteilung der Daten vorausgesetzt wird. Diese Eigenschaft macht den Spearman-Koeffizienten besonders geeignet für biologische Daten.

2.4.2 Mutual Information

Sind zwei Variablen nicht unabhängig voneinander, lässt sich von der einen Variable mit gewisser Wahrscheinlichkeit auf die andere schliessen [31]. Diese Wahrscheinlichkeit lässt sich mit der “gegenseitigen Information” (Mutual Information oder **MI**) quantifizieren.

⁶Zum Beispiel erhält der kleinste Wert den Rang 1 und der zweitkleinste Wert den Rang 2. Der grösste von n Werten besitzt den Rang n.

Für normalverteilte Daten kann die gegenseitige Information I aus dem Spearman-Koeffizienten r berechnet werden [26], [32]:

$$I(X_i, Y_i) = -\frac{1}{2} \log(1 - r^2)$$

Falls $I = 0$ ist, enthält eine Variable keine Information über eine andere. Ein höherer MI-Wert zwischen zwei Variablen bedeutet, dass die eine auf eine nicht zufällige Art mit der anderen verwandt ist. In diesem Sinne ist die Annahme sinnvoll, dass zwei Gene umso wahrscheinlicher eine biologische Verwandtschaft haben, desto höher ihr gemeinsamer MI-Wert ist [33].

2.4.3 Weitere Grundlagen der Statistik

Nullhypothese H_0

Eine H_0 ist eine Annahme in der Statistik, die besagt, dass es keinen Effekt, keinen Zusammenhang oder **keinen Unterschied zwischen Variablen** gibt, und die mit einem Hypothesentest überprüft wird. Sie wird solange als wahr angesehen, bis statistische Beweise sie widerlegen, und bildet das Gegenstück zur Alternativhypothese H_1 [34], [35].

p-Wert

Der p-Wert ist definiert als die Wahrscheinlichkeit, die Teststatistik oder einen noch höheren Wert zu erhalten, unter der Annahme, dass H_0 wahr ist. Ein kleiner p-Wert signalisiert, dass die Beobachtung unter der Annahme des Zufalls sehr unwahrscheinlich ist, was zur Verwerfung von H_0 führt.

Bernoulli-Experiment

Ein Bernoulli-Experiment ist ein **Zufallsexperiment mit genau zwei möglichen Ergebnissen**, die als “Erfolg” und “Misserfolg” bezeichnet werden. Die Erfolgswahrscheinlichkeit bleibt durch Prozesse wie beispielsweise “Zufälliges Ziehen mit Zurücklegen” konstant [36].

3 Methodik

3.1 Daten

Der verwendete Datensatz stammte aus der öffentlichen Datenbank **Gene Expression Omnibus** (**GEO**-Accession: GSE128816; $n_{test} = 10$, $n_{control} = 10$) [37] und entstammt einer Studie zur Untersuchung der Wirkung von **VitD3**-induzierten tolerogenen dendritischen Zellen (**VitD3-tolDC**) auf CD4+ T-Zellen.

3.1.1 Generierung und Charakterisierung des Datensets

Die Erstellung des Datasets erfolgte in einem mehrstufigen In-Vitro-Verfahren [38].

Zellkultur und Erzeugung der tolerogenen Bedingungen

Zunächst wurden **CD14⁺ Monozyten** aus Buffy Coats **gesunder Spender** isoliert und über sechs Tage in X-VIVO 15-Medium (supplementiert mit **IL-4** und **GM-CSF**) **zu dendritischen Zellen differenziert**. Zur Induktion des tolerogenen Profils wurden die Zellen an den Tagen 0 und 4 mit 1 nM **Vitamin D3** behandelt. Am vierten Tag erfolgte die Beladung mit dem Modellantigen **TT** (**TT**) sowie die Zugabe eines Maturation-Cocktails (**IL-1 β** , **TNF- α** , PGE2), um die Stabilität der Zellen unter entzündlichen Bedingungen zu testen. Parallel dazu wurden reife dendritische Zellen (**mDC**) ohne **VitD3**-Zugabe als immunogene Kontrolle generiert.

Ko-Kultur und RNA-Sequenzierung

Die so erzeugten **DC**-Subtypen wurden in einem Verhältnis von 1:20 mit **autologen peripheren mononukleären Blutzellen** (PBMC) für fünf Tage ko-kultiviert. Nach Ablauf der Kultur wurden die CD3+CD4+ T-Zellen mittels Fluoreszenz-aktivierter Zellsortierung (**FACS**) isoliert. Die transkriptomische Analyse erfolgte über eine **Paired-end RNA-Sequenzierung** (HiSeq-2500, Illumina), wobei nur Proben mit einem RNA-Integritätswert (**RIN**) von > 7 für die finale Analyse verwendet wurden.

Datensatz-Zusammensetzung und Relevanz

Die Ergebnisse der Studie zeigen eine tiefgreifende **transkriptomische Repression in den T-Zellen** nach Kontakt mit **VitD3-tolDC**. Von den 16'333 analysierten proteinkodierenden Genen wiesen 373 eine signifikante differenzielle Expression auf

($p_{adj} < 0.05$). Besonders relevant für die Modellierung des Netzwerks ist, dass 92% dieser Gene (344 Gene) **herunterreguliert** wurden. Diese Gene sind primär in biologischen Prozessen wie dem Zellzyklus, der DNA-Replikation und der metabolischen Aktivität involviert. Das Datenset liefert somit eine präzise Grundlage, um die regulatorischen Knotenpunkte zu identifizieren, die den Übergang einer T-Zelle von einem aktivierten in einen hyporesponsiven (toleranten) Zustand steuern.

3.1.2 Normalisierung

Die beschriebenen Daten wurden $\log_2(x + 1)$ -**verwandelt**¹, um aus einer exponentiell-lähnlichen eine (möglichst) normale Verteilung zu erhalten [39]. Zur Vergleichbarkeit der Expressionswerte zwischen den Bedingungen wurde eine **Quantilnormalisierung** (qspline) durchgeführt [40]. Dieses Verfahren gleicht systematische Unterschiede in den Signalverteilungen der Arrays aus, um sicherzustellen, dass beobachtete Unterschiede biologischen und nicht technischen Ursprungs sind. Dabei werden die Quantile der ursprünglichen Verteilungen an eine gemeinsame Zielverteilung angepasst.

In einem QQ-Plot ist diese Anpassung graphisch erkennbar: Die x-Achse zeigt die “theoretical quantiles” (die Quantile, die man bei einer perfekten Normalverteilung erwarten würde) an. Nach der Normalisierung sollten ihnen die “sample quantiles” (die tatsächlich beobachteten Quantile) auf der y-Achse entsprechen – die Punkte sollten also genau auf der Diagonalen liegen.

3.2 Materialien und Software

Alle statistischen Berechnungen und bioinformatischen Analysen wurden in der Programmiersprache **R** (Version 4.4.3) [41] der Entwicklungsumgebung **RStudio** (Version 2025.09.0+387) [42] durchgeführt. Für die jeweiligen Analyseschritte kamen die nachfolgenden R-Pakete aus dem Bioconductor- und dem CRAN-Repository zum Einsatz (Tab. 2):

Die grundlegenden Analysen erfolgten auf einem Windows-Laptop (Intel i7-1165G7, 16 GB RAM), während der Permutationstest auf einem MacBook Pro (M5-Prozessor, 32 GB RAM) durchgeführt wurde.

3.3 Netzwerkerstellung mit BC3NET

Zur Erstellung des Genregulationsnetzwerks aus den vorliegenden Genexpressionsdaten wurde die Methode **Bagging C3NET** (**BC3NET**) verwendet [32].

¹Der sogenannte “Pseudocount” von 1 wird allen Werten addiert, um das nicht definierte $\log(0)$ zu vermeiden.

Tabelle 2: Verwendete R-Pakete und deren Versionen.

Paket	Version	Repository	Quelle
bc3net	1.0.5	CRAN	[43]
WGCNA	1.73	CRAN	[44]
RColorBrewer	1.1.3	CRAN	[45]
preprocessCore	1.68.0	Bioconductor	[46]
igraph	2.1.4	CRAN	[47]
moduleColor	1.8.4	CRAN	[48]
scales	1.4.0	CRAN	[49]
dplyr	1.1.4	CRAN	[50]
ggplot2	4.0.0	CRAN	[51]
flashClust	1.01-2	CRAN	[52]
clusterProfiler	4.14.6	Bioconductor	[53]
org.Hs.eg.db	3.20.0	Bioconductor	[54]
enrichplot	1.26.6	Bioconductor	[55]

BC3NET ist ein sogenanntes **Ensemble-Verfahren**, das speziell darauf ausgelegt ist, aus grossen, aber oft verrauschten biologischen Datensätzen robuste und zuverlässige Netzwerke zu extrahieren. Die Kernidee besteht darin, nicht nur ein einziges Netzwerk aus den Daten zu berechnen, sondern eine Vielzahl von Netzwerken zu erstellen und diese anschliessend zu einem finalen, statistisch validierten Netzwerk zu vereinigen. Dieser Ansatz erhöht die Zuverlässigkeit der Ergebnisse erheblich und reduziert die Anfälligkeit für zufällige Schwankungen oder Ausreisser in den Daten. Der Algorithmus lässt sich in drei konzeptionelle Hauptschritte (Abb. 10) unterteilen, die im Folgenden erläutert werden.

3.3.1 Erstellung eines Bootstrap-Ensembles (Bagging)

Genexpressionsdaten sind durch komplexe Eigenschaften gekennzeichnet: Sie sind hochdimensional (Tausende von Genen), oft nicht linear und enthalten technisches sowie biologisches Rauschen. Zudem steht einer grossen Anzahl von Genen p (Variablen) typischerweise nur eine kleine Anzahl von Proben n gegenüber (“Large p small n ”) [56].

Um diesen Herausforderungen zu begegnen, wendet **BC3NET** das Prinzip der **Bootstrap Aggregation**, kurz **Bagging**, an. Aus dem ursprünglichen, einzelnen Genexpressionsdatensatz D wird nicht nur ein Netzwerk, sondern ein ganzes Ensemble von




Abbildung 10: Schematische Abbildung des **BC3NET**-Algorithmus [32]. Aus einem Datensatz D werden B Bootstraps erstellt. Auf jeden dieser Bootstraps wird der **C3NET**-Algorithmus zur Korrelationsberechnung angewendet. Die entstehenden Netzwerke G_k^b ($k = 1$) ^{B} werden dann zu einem ungerichteten, gewichteten Finalnetzwerk G_w^b zusammengeführt. Anschliessend wird zur Validierung der Kanten ein Binomialtest durchgeführt.

Netzwerken abgeleitet. Für diese Arbeit wurden dafür zunächst aus dem Originaldatensatz wurden durch **zufälliges Ziehen mit Zurücklegen** hundert ($B = 100$) neue, sogenannte **Bootstrap-Datensätze** ($D_1, D_2, \dots, D_B$) erstellt [57], [58]. Jeder dieser Bootstrap-Datensätze war dem Originaldatensatz sehr ähnlich, aber dennoch einzigartig in seiner Zusammensetzung. Dieses Vorgehen simulierte gewissermassen, wie die Ergebnisse aussehen würden, wenn das Experiment viele Male wiederholt werden würde.

3.3.2 Netzwerkinferenz mit C3NET für jeden Bootstrap-Datensatz

Für jeden einzelnen der hundert erstellten Bootstrap-Datensätze wurde nun mithilfe des **C3NET-Algorithmus** ein Koexpressionsnetzwerk berechnet. **C3NET** ist ein recheneffizienter Algorithmus, der seinerseits in drei Schritten arbeitet:

1. **Berechnung der Mutual Information:** Zuerst wurden für alle möglichen Gen-Paare als Mass für ihre statistische Abhängigkeit die **MI** berechnet. **BC3NET** berechnete zunächst den Spearman-Korrelationskoeffizienten und wandte diesen anschliessend in einen MI-Wert um².
2. **Eliminierung schwacher Verbindungen:** Für jedes Gen wurde nur die stärkste Verbindung zu einem anderen Gen beibehalten; **pro Gen** konnte es also **maximal eine Kante** geben. Alle anderen potenziellen Verbindungen dieses Gens verwarf **C3NET**. Dieser **konservative** Schritt sorgte dafür, dass nur die signifikantesten

²**BC3NET** ist in der Lage, mit MI-Estimators anstatt von Korrelationskoeffizienten zu rechnen, um nichtlineare Daten zu berücksichtigen. Für normale Daten lässt sich jedoch auch aus den Korrelationskoeffizienten die Mutual Information berechnen.

Interaktionen im Netzwerk verblieben und verhinderte, dass das Netzwerk zu dicht und unübersichtlich wurde.

3. **Fehlerkontrolle:** Die Bonferroni-Korrektur für multiples Testen wurde angewendet, um die Anzahl der zufällig gefundenen Verbindungen zu kontrollieren (siehe Anhang).

Als Ergebnis dieses zweiten Schrittes lag ein Ensemble von B leicht unterschiedlichen Netzwerken $G_{k=1}^{bB}$ vor, die jeweils die stärksten Verbindungen jedes Gens in dem entsprechenden Bootstrap-Datensatz repräsentierten.

3.3.3 Aggregation und statistische Validierung

Alle Netzwerke des Ensembles wurden zu einem **gewichteten Netzwerk** G_w^b zusammengeführt. Das Gewicht einer Kante n_{ij} entsprach dabei der absoluten Häufigkeit, mit der diese spezifische Kante in den B Einzelnetzwerken vorkam:

$$G_w^b(i, j) = \sum_{k=1}^B I(G_k^b(i, j))$$

wobei die Indikatorfunktion $I()$ definiert ist als:

$$I(x) = \begin{cases} 1, & x = 1 \\ 0, & \text{sonst} \end{cases}$$

Eine Kante, die beispielsweise in 95 von 100 Bootstrap-Netzwerken auftrat, wies ein hohes Gewicht auf und wurde entsprechend als robust betrachtet. Trat eine Kante dagegen nur in 20 Netzwerken auf, deutete dies auf eine geringere Zuverlässigkeit hin.

Statistischer Test für jede Kante

Anstatt einen willkürlichen Schwellenwert festzulegen (z.B. “Behalte alle Kanten, die in mehr als 30 der Netzwerke vorkommen”), führte **BC3NET** für jede potentielle Kante einen **statistischen Hypothesentest** durch. Die Nullhypothese H_0 lautete, dass die beobachtete Häufigkeit einer Kante nicht höher war als rein zufällig erwartet. Da die B Bootstrap-Datensätze voneinander unabhängig waren, konnte das wiederholte Schätzen eines Netzwerks als eine Serie von B **unabhängigen Bernoulli-Experimenten** betrachtet werden. In jedem dieser Experimente besass die Kante (i, j) genau zwei mögliche Ausgänge: “vorhanden” (Erfolg) oder “nicht vorhanden” (Misserfolg). Unter H_0 folgte die Anzahl der Beobachtungen einer Kante, also die Teststatistik n_{ij} , somit einer **Binomialverteilung**³ [59]

$$n_{ij} \sim \text{Bin}(B, p_c)$$

³Die Binomialverteilung beschreibt die Anzahl Erfolge in einer Serie von Bernoulli-Experimenten. Ist p die Erfolgswahrscheinlichkeit bei einem Versuch, dann bezeichnet $\text{Bin}(k, p)$ die Wahrscheinlichkeit, genau k Erfolge zu erzielen.

wobei p_c die Wahrscheinlichkeit bezeichnete, dass zwei Gene rein zufällig durch eine Kante verbunden waren. Dieser Wert wurde von **BC3NET** u.a. basierend auf der Grösse des Datensets geschätzt. Nachdem für jede Kante (i, j) die Anzahl der beobachteten Erfolge n_{ij} bestimmt wurde, erfolgte die statistische Bewertung. Entscheidend war, ob n_{ij} so hoch war, dass eine zufällige Fluktuation unwahrscheinlich wurde und auf eine echte biologische Interaktion hingedeutet werden konnte. Der p-Wert für eine Kante (i, j) entsprach der Wahrscheinlichkeit, unter Annahme von H_0 mindestens so viele Erfolge zu erhalten wie beobachtet:

$$p(i, j) = \Pr(n \geq n_{ij}) = \sum_{n=n_{ij}}^B \binom{B}{n} p_c^n (1 - p_c)^{B-n}$$

Jeder Summand $\binom{B}{n} p_c^n (1 - p_c)^{B-n}$ war die Wahrscheinlichkeit, in genau n der B Bootstrap-Netzwerke das zufällige Auftreten der Kante zu beobachten. Die Binomialkoeffizienten $\binom{B}{n}$ gaben dabei die Anzahl möglicher Kombinationen dieser n Erfolge an.

Erstellung des finalen Netzwerks

Nur die Kanten, deren p-Wert unter einem strengen, für multiples Testen korrigiertes Signifikanzniveau lag (Bonferroni-Korrektur), wurden in das endgültige, **ungerichtete Netzwerk G** aufgenommen.

Bedeutung

Dieser statistisch fundierte Ansatz ist ein wesentlicher Vorteil von **BC3NET**, da er eine objektive und reproduzierbare Methode zur Auswahl der finalen Kanten bietet und die Notwendigkeit **manueller Schwellenwerte eliminiert**. Das resultierende Netzwerk G repräsentierte somit ein konservatives, aber statistisch signifikantes Abbild der stärksten und robustesten Zusammenhänge in den Genexpressionsdaten.

3.3.4 Praktische Umsetzung

Für diese Arbeit wurde die Implementierung der Autoren im R-Paket “bc3net” genutzt (Code-Block 3.1). Als Ähnlichkeitsmass diente der **Spearman**-Korrelationskoeffizient. Die Anzahl der Bootstraps wurde auf 100 gesetzt, um eine stabile Netzwerkkonvergenz bei gleichzeitig akzeptabler Rechenzeit zu erreichen. Anschliessend wurde das erstellte igraph-Objekt (Netzwerk) in eine Adjazenzmatrix umgewandelt.

3.4 Skalenfreie Topologie und der Parameter beta1

Der optimale Soft-Threshold beta1 wurde mithilfe der Funktion **pickSoftThreshold.fromSimilarity** bestimmt (Code-Block 3.2). Als skalenfrei wurde ein Netzwerk erachtet, wenn er einen R^2 -Wert von über 0.85 erreicht.

Code 3.1: Berechnung der Netzwerke mit BC3NET

```
1 library(igraph)
2 library(bc3net)
3 library(WGCNA)
4 netControl <- bc3net(datControl, verbose=TRUE, estimator="
    spearman", boot=100)
5 netTest <- bc3net(datTreated, verbose=TRUE, estimator="spearman"
    , boot=100)
6 save(netControl, file = "netControl.RData")
7 save(netTest, file = "netTest.RData")
8 adjMatControl <- as_adjacency_matrix(netControl, attr="weight",
    sparse=F)
9 adjMatTreated <- as_adjacency_matrix(netTest, attr="weight",
    sparse=F)
10 genesTreated <- V(netTest)$name # get the names of all the
    treated genes
11 adjMatControl <- adjMatControl[genesTreated, genesTreated] #
    only keep genes present in treated
12 collectGarbage()
```

Code 3.2: Die Wahl von beta1

```
1 powers <- c(seq(1,10,1), seq(12,20,2))
2
3 sft = pickSoftThreshold.fromSimilarity(
4     similarity = AdjDiff,
5     powerVector = powers,
6     RsquaredCut = 0.85,
7     moreNetworkConcepts = TRUE,
8     verbose = 5);
9
10 beta1 <- sft$powerEstimate
```

Code 3.3: Visualisierung der Netzwerke

```

1 componentsInfoTest <- components(netTest)
2 giantTest <- induced_subgraph(netTest,
3                               which(componentsInfoTest$
4                                   membership == which.max(
5                                       componentsInfoTest$csize)))
6 comTest <- cluster_louvain(giantTest)
7 V(giantTest)$color <- brewer.pal(n = length(comTest), name = "
8   Set3")[comTest$membership]
9 edgeColorFnTest <- col_numeric(palette = c("#fff", "#404040"),
10                                domain = NULL)
11 E(giantTest)$color <- edgeColorFnTest(E(giantTest)$weight)
12 pdf("netTest.pdf", width = 12, height = 12)
13 plot(giantTest,
14      layout = layout_with_drl(giantTest),
15      vertex.label = NA,
16      vertex.size = 1,
17      vertex.frame.color = NA,
18      edge.arrow.mode = 0)
19 dev.off()

```

3.5 Grobe Netzwerkbeschreibung

Für eine grobe Beschreibung der mit **BC3NET** erstellten Netzwerke erfolgte zunächst eine graphische Darstellung mit **igraph**. Das hierarchische Clustering wurde mit der Louvain-Methode⁴ durchgeführt [60], [61]. Code-Block 3.3 visualisiert den grössten zusammenhängenden Teil, die sogenannte “**Giant Component**”, des netTest-Netzwerks und färbt die Knoten und Kanten nach Clusterzugehörigkeit bzw. nach Kantengewicht ein. Bei der Layout-Erstellung kam **DrL**⁵ zum Einsatz, da sich diese Methode gut für die Visualisierung grosser Netzwerke eignet [62], [63]. netControl wurde auf gleiche Weise visualisiert.

Anschliessend wurden für beide Netzwerke Dichte, Durchmesser und durchschnittlicher Knotengrad berechnet sowie die Anzahl Kanten bzw. Knoten gezählt.

⁴Die **Louvain-Methode** ist ein Greedy-Algorithmus und identifiziert sich nicht überschneidende Cluster.

⁵In DrL-Graphen sind nahverwandte Knoten nah aneinander, während entferntere Verbindungen nach aussen verschoben werden.

3.6 DiffCoEx

Um die Unterschiede in den Gen-Interaktionsmustern zwischen den beiden analysierten Zuständen zu identifizieren, kam die Methode **Differentially CoExpressed gene modules** (**DiffCoEx**) zum Einsatz [25]. **DiffCoEx** versucht, ganze Module von Genen zu identifizieren, deren gemeinsames Expressionsmuster (ihre Koexpression) sich signifikant zwischen den beiden Bedingungen ändert. Anders als bei der normalen Clustersuche enthalten die gefundenen Module also nicht koexprimierte Gene; stattdessen gruppiert **DiffCoEx** Gene, welche ihre **Verbindungsstärke** zu denselben anderen Genen **auf eine ähnliche Art ändern** ⁶ (Abb. 11).




Abbildung 11: Klassische Modulsuche vs. DiffCoEx, eigene Abbildung. Einfaches Beispielnetzwerk mit den vier Genen A, B, C und D. Klassische Clustering-Algorithmen identifizieren Module von koexprimierten Genen innerhalb einer Bedingung. DiffCoEx hingegen untersucht Verbindungen, die sich zwischen zwei Zustände verändern und erstellt infolgedessen andere Module.

DiffCoEx nutzt **WGCNA**, ein R-Paket mit verschiedenen Funktionen zur Erstellung von gewichteten Koexpressionsnetzwerken, wendet es aber nicht auf die Expressionsdaten selbst an, sondern auf die **Veränderung der Korrelationen** zwischen den beiden

⁶Bei der gewöhnlichen Clustersuche wird eine einzelne Adjazenzmatrix als Eingabe für das Topological Overlap Measure (TOM) verwendet. Diese beschreibt die Korrelationsstärke zwischen Genen in einem Zustand (Test- oder Kontrollgruppe). Die entstehende TOM-Matrix beschreibt daher Gene, welche in diesem Zustand dieselben Korrelationspartner (Nachbarn) haben. Das Ergebnis sind Module von Genen, die miteinander koexprimiert sind.

Zuständen. Der grosse Vorteil ist, dass die Methode **unvoreingenommen** ist. Sie kann also de novo Gen-Module auf Basis gemeinsamer Unterschiede in den Korrelationsmustern finden, ohne auf bereits bekannte Gen-Gruppen angewiesen zu sein. Dabei folgt **DiffCoEx** einem fünfteiligen Prozess (Abb. 12).




Abbildung 12: **DiffCoEx**-Workflow, eigene Abbildung. Aus den Adjazenzmatrizen der Test- und Kontrollgruppe wird eine Differenzmatrix berechnet. Diese dient als Grundlage für die **TOM**-basierte Dissimilaritätsmatrix, welche dann in Cluster aufgespalten wird. Als letzter Schritt wird die Signifikanz der entstandenen Cluster ermittelt (z.B. mit Permutationstests).

3.6.1 Adjazenzmatrizen als Ausgangslage

Die Grundlage für die Analyse bilden die für jeden Zustand erstellten Adjazenzmatrizen aus der **BC3NET**-Analyse. In diesen Matrizen ist für jedes Genpaar ein Wert hinterlegt, der die Stärke seiner statistischen Verbindung (Koexpression) repräsentiert.

3.6.2 Berechnung der Adjazenzdifferenz-Matrix

Im zweiten Schritt werden die beiden Adjazenzmatrizen verrechnet, um eine einzige **Adjazenzdifferenz-Matrix** zu erstellen. Ein hoher Wert in dieser Matrix bedeutet, dass sich die Koexpression zwischen zwei Genen stark zwischen den beiden Zuständen unterscheidet (z.B. hohe Korrelation in der Testgruppe, aber tiefe Korrelation in der Kontrolle). Ein tiefer Wert bedeutet, dass ihre Verbindung stabil geblieben ist.

3.6.3 Topologischer Overlap zur Identifikation gemeinsamer Muster

In einem nächsten Schritt wird der **Topologische Overlap Measure (TOM)** berechnet. Zwei Gene werden hier als “ähnlich” betrachtet, wenn sie signifikante Korrelationsänderungen mit derselben Gruppe von Nachbargenen aufweisen. Hierbei wird ein sogenannter Soft-Threshold-Parameter (β_1) verwendet. Dieser dient dazu, grosse und damit bedeutsame Korrelationsunterschiede stärker zu gewichten als kleine, potenziell durch Rauschen verursachte Unterschiede. Konzeptionell funktioniert dieser Parameter wie ein Verstärker für die relevantesten Signale in den Daten. Für die Wahl von β_1 wurde versucht, ein Netzwerk zu erstellen, welches das Skalenfreiheits-Kriterium erfüllte.

Dieser Ansatz ermöglicht die Entdeckung von zwei wesentlichen Arten differentieller Koexpression (Abb. 13):

- A **Innerhalb-Modul-Änderung:** Eine Gruppe von Genen ist in Zustand 1 stark miteinander korreliert, in Zustand 2 jedoch kaum noch (oder umgekehrt). Das gesamte Modul verliert oder gewinnt also seinen inneren Zusammenhalt.
- B **Zwischen-Modul-Änderung:** Zwei Gen-Module A und B werden in beiden Zuständen intern stabil koexprimiert. Jedoch korrelieren die Gene aus Modul A in Zustand 1 stark mit den Genen aus Modul B, während diese Verbindung in Zustand 2 verloren geht. Die Methode erkennt dies, weil alle Gene in Modul A ein ähnliches Muster der “Verbindungsänderung” zu den Genen in Modul B aufweisen.

Aus dieser Berechnung resultiert eine Dissimilaritätsmatrix, welche die Unähnlichkeit zwischen allen Genpaaren auf Basis ihrer gemeinsamen “Veränderungs-Nachbarschaft” beschreibt. In dieser Matrix stellt ein tiefer Wert eine hohe Ähnlichkeit (niedrige Unähnlichkeit) dar: Dies bedeutet, dass Gen i und j mit denselben Nachbarn eine signifikante Korrelationsänderung aufweisen. Diese Korrelationsänderung ist ihr “topologischer Overlap”.

3.6.4 Clustering und Modul-Identifikation

Die im vorherigen Schritt erstellte Dissimilaritätsmatrix dient nun als Input für ein hierarchisches Clustering. Dabei werden die Gene in einem baumartigen Diagramm (Dendrogramm) angeordnet, wobei ähnliche Gene nahe beieinander liegen. Anschliessend wird dieser Baum mithilfe des Algorithmus Dynamic Tree Cut in einzelne Äste geschnitten, welche die finalen differentiell koexprimierten Module darstellen. Die Schnitthöhe cutHeight wird dabei empirisch bestimmt: Für Werte zwischen 0.90 und 0.999 analysiert die Arbeit schrittweise, wie sich die Anzahl der Module und deren mediane Grösse verändern. Die Ergebnisse werden grafisch dargestellt, wodurch sich ein Bereich erkennen lässt, in dem sich beide Grössen stabilisieren.




Abbildung 13: Differential-Koexpressionsszenarios [25]. Fall A: Das Gennetzwerk ist in Bedingung 1 koexprimiert. In Bedingung 2 ist ein wichtiger Regulator jedoch inaktiv und das Modul ist nicht länger koexprimiert. Fall B: Zwei ansonsten unabhängige Signalwege werden in Bedingung 1 durch das blau markierte Gen koordiniert. Seine Inaktivität in Bedingung 2 entfernt die Korrelation zwischen den beiden Modulen – doch die Korrelation innerhalb der Module bleibt bestehen.

3.6.5 Statistische Signifikanzprüfung

Um die Signifikanz der beobachteten Unterschiede in der Netzwerkstruktur zwischen den Bedingungen zu prüfen, wurde ein Permutationstest durchgeführt. Ziel dieses Verfahrens ist es zu bestimmen, ob die berechneten Dispersionswerte der Genmodule statistisch signifikant sind oder lediglich durch die natürliche Variabilität der Daten entstehen.

Berechnung des Dispersionsmasses

Zunächst wurde für jedes Paar von Genmodulen (c_1, c_2) ein Dispersionswert berechnet. Hierbei wurde für beide experimentellen Bedingungen jeweils ein Gennetzwerk mittels des bc3net-Algorithmus (basierend auf Spearman-Korrelation und Bootstrapping) erstellt. Der Dispersionswert ergibt sich aus der Differenz der Adjazenzmatrizen beider Bedingungen:

$$D = \sqrt{\frac{1}{N} \sum |A_1 - A_2|^\beta}$$

Dabei repräsentieren A_1 und A_2 die gewichteten Adjazenzmatrizen der jeweiligen Bedingungen und N die Anzahl der betrachteten Genpaare. Ein hoher Wert deutet

auf eine starke Veränderung der regulatorischen Interaktionen zwischen den Bedingungen hin.

Erzeugung der Nullhypothese (Permutation)

Zur Erstellung einer Nullverteilung wurden die Proben beider Bedingungen 1000-mal zufällig vertauscht (Permutation). Durch dieses Mischen der Stichproben wird die ursprüngliche Gruppenzugehörigkeit (z. B. “Kontrolle” vs. “Behandlung”) aufgehoben, während die generelle Datenstruktur erhalten bleibt. Für jede dieser 1000 Zufallskonstellationen wurde der Dispersionswert erneut berechnet, um zu ermitteln, welche Differenzen rein zufällig zu erwarten wären.

Bestimmung der Signifikanz

Abschliessend wurde der tatsächlich beobachtete Dispersionswert mit der generierten Nullverteilung verglichen. Die Signifikanz (entsprechend dem p-Wert-Prinzip) wurde berechnet, indem gezählt wurde, wie viele der zufälligen Permutationen einen Dispersionswert erreichten, der grösser oder gleich dem realen Beobachtungswert war:

- Hohe Signifikanz: Nur sehr wenige oder keine der Zufallspermutationen (z. B. weniger als 50 von 1000) übertreffen den realen Wert. Dies deutet darauf hin, dass die Veränderung im Netzwerk biologisch relevant und nicht zufällig ist.
- Geringe Signifikanz: Viele Permutationen liefern ähnliche oder höhere Werte als die Originaldaten; der beobachtete Effekt ist statistisch nicht belastbar.

3.7 Genset-Analyse

Die Over-Representation-Analyse (**ORA**) ist ein weit verbreitetes Verfahren, um zu bestimmen, ob bestimmte **bekannte biologische Funktionen** oder Prozesse in einer experimentell abgeleiteten Genliste überrepräsentiert (angereichert) sind. Für diese Arbeit wurde untersucht, welche a priori definierten, ungeordneten Sammlungen von Genen (**Gensets**) [64], in einer Untermenge von “interessanten” Genen häufiger vorkamen, als es zufällig zu erwarten wäre [65], [66]. Der p-Wert für die **Überrepräsentation** (engl. enrichment) kann mit einem hypergeometrischen Verteilungstest berechnet werden:

$$p = P(X \geq x) = 1 - P(X \leq x - 1) = 1 - \sum_{i=0}^{k-1} \frac{\binom{M}{i} \binom{N-M}{n-i}}{\binom{N}{n}}$$

Nach der Berechnung des p-Werts wurde die **BH-Korrektur** für multiples Testen angewandt werden (siehe Anhang).

3.7.1 Gene Ontology (GO)

Die Anreicherungsanalyse nutzte die Datenbank **Gene Ontology** (**GO**). Diese hat drei Kategorien (Tab. 3) [64], [67]:

Tabelle 3: GO-Kategorien und ihre Beschreibungen.

Kategorie	Beschreibung
Molecular Function (MF)	Beschreibt die biochemischen Aktivitäten eines von einem einzelnen Genprodukt (z. B. Protein oder RNA). Sie gibt an, was ein Genprodukt tun kann, jedoch nicht, wo oder wann es dies tut.
Cellular Component (CC)	Beschreibt den Ort innerhalb der Zelle, an dem eine molekulare Funktion stattfindet.
Biological Process (BP)	Beschreibt übergeordnete biologische Abläufe, die durch das Zusammenspiel vieler molekularer Funktionen entstehen.

3.7.2 Praktische Umsetzung

Die Berechnung erfolgte mithilfe der Funktion `enrichGO` des Moduls `clusterProfiler` (Code-Block 3.4).

3.8 Vergleich mit anderen Datensets

Zur weiterführenden statistischen Validierung wurden zwei weitere relevante Datensets (GSE55235: Identification of rheumatoid arthritis and osteoarthritis patients by transcriptome-based rule set generation, GSE133426: Human memory Th17 cell populations change into anti-inflammatory cells with regulatory capacity upon exposure to active Vitamin D) analysiert und mit GSE128816 verglichen [68], [69]. Die Analyse erfolgte jeweils innerhalb der GEO-Website mittels GEO2R; die gefundenen differenziell exprimierten Gene wurden anschliessend mit den in GSE128816 gefundenen Module verglichen.


Code 3.4: Functional Enrichment

```
1 # Convert gene symbols to Entrez IDs for each module
2 modulesMergedEntrez <- lapply(modulesMerged, function(gene_set)
3   {
4     result <- bitr(gene_set,
5                   fromType="SYMBOL",
6                   toType="ENTREZID",
7                   OrgDb = org.Hs.eg.db)
8     return(result$ENTREZID)
9   })
10 # Perform GO enrichment analysis for each module
11 enrichmentResults_ontALL <- lapply(modulesMergedEntrez, function
12   (gene_set) {
13     enrichGO(
14       gene = gene_set,
15       OrgDb = org.Hs.eg.db,
16       keyType = "ENTREZID",
17       ont = "ALL",
18       pAdjustMethod = "BH",
19       readable = TRUE,
20       pvalueCutoff = 0.05,
21       qvalueCutoff = 1)
22   })
```


4 Ergebnisse

4.1 Normalisierung

Nach der **log2-Transformation** veränderte sich die Verteilung der Expressionswerte deutlich: Der ursprünglich exponentielle Verlauf mit einer ausgeprägten Spitze bei $x = 0$ (Abb. 14a) flachte ab. Stattdessen zeigte sich eine breitere, gestreckte Hauptspitze bei etwa $x = 9$ (Abb. 14b). Auffällig war zudem ein **lokales Maximum bei $x = 0$** sowie ein **Plateau zwischen $x = 0$ und $x = 7$** , bevor die Verteilung ab etwa $x = 7$ annähernd einer Normalverteilung entsprach.




(a) Rohdaten, eigene Abbildung. Auf der x-Achse ist der Wert der Expression angegeben. Die y-Achse beschreibt die Anzahl Gene, welche diesen Wert besitzen ("density"). Man erkennt deutlich eine Spitze bei ca. $x=0$ und wie die Häufigkeit daraufhin exponentiell abnimmt.




(b) log2-verwandelte Daten, eigene Abbildung. Hier zeigt die x-Achse den log2-verwandelten Wert der Expression, während die y-Achse wieder die «density» beschreibt. Die Spitze wurde auf die Werte zwischen etwa 7 und 10 gestreckt. Ein lokales Maximum bei $x=0$ wird in dieser Abbildung ebenfalls erkennbar.

Nach der **Quantilnormalisierung** zeigte sich im Q-Q-Plot (Abb. 15b) eine deutlich verbesserte Übereinstimmung der empirischen mit den theoretischen Quantilen. Während die Daten vor der Normalisierung (Abb. 15a) stark von der Diagonalen abwichen, verliefen die Punkte nach der Normalisierung weitgehend linear. Lediglich im unteren Bereich ($x < 0$) war eine Abflachung zu erkennen, was darauf hindeutet, dass sehr

niedrige Intensitätswerte durch die Normalisierung auf einen engen Wertebereich zusammengezogen wurden.



(a) Q-Q-Plot der Rohdaten, eigene Abbildung. In der x-Achse sind die theoretisch erwarteten, in der y-Achse die tatsächlich beobachteten Quantile. Die Kurve steigt exponentiell an.



(b) Q-Q-Plot der log2-verwandelten, quantil-normalisierten Daten, eigene Abbildung. Bis zum theoretischen Quantil -1 (x-Achse) sind die empirischen Quantile (y-Achse) gleich 0. Im Bereich von -1 bis 0 steigt Kurve stark an und verläuft ab ca. 0 nahezu linear entlang der Diagonalen.

4.2 BC3NET-Netzwerke

Für beide Bedingungen (Test- und Kontrollgruppe) wurde die grösste zusammenhängende Komponente (“Giant Component”) der mit **BC3NET** inferierten Koexpressionsnetzwerke bestimmt und mit **igraph** visualisiert (Abb. 16). Beide Netzwerke umfassten 16333 Gene (Knoten), unterschieden sich jedoch leicht in ihrer Topologie (Tab. 16). Das Netzwerk der Testgruppe (netTest) enthielt 117706 Kanten und wies damit eine leicht höhere Dichte ($8.825 \cdot 10^{-4}$) als das Kontrollnetzwerk netControl mit 114537 Kanten (Dichte: $8.588 \cdot 10^{-4}$) auf. Der durchschnittliche Knotengrad war mit 14.41 gegenüber 14.03 geringfügig erhöht, während der Durchmesser mit 2.04 im Vergleich zu 1.73 leicht grösser war. In Abbildung 20 ist zudem erkennbar, dass die Gradverteilungen der beiden Netzwerke nur ab einem x-Achsen-Wert von 2 annähernd dem **Potenzgesetz** (Kap. 2.3.4) entsprachen.

4.3 Skalenfreie Topologie

Keiner der vorgeschlagenen “powers” erreichte den R^2 -Cut von 0.85; somit konnte mit keinem Parameter eine annähernd skalenfreie Topologie für die **TOM**-Dissimilaritätsmatrix




Abbildung 16: igraph-Darstellung des Test- (links) und des Kontrollnetzwerks (rechts), eigene Abbildung. Jeder Punkt stellt ein Gen, jede Linie eine Korrelation zwischen zwei Genen dar. Innerhalb der beiden Netzwerke sind die Gene mit Farben nach Modul gruppiert. (Rechts und links stehen die Farben für unterschiedliche Module.)




Abbildung 17: Beobachtete Gradverteilung, eigene Abbildung. Jeder Punkt in diesem Graphen stellt die Anzahl Knoten (Gene) auf der y-Achse mit einer bestimmten Anzahl Kanten (Verbindungen) auf der x-Achse dar. Die Gene im markierten Bereich weichen von der skalenfreien Optimalverteilung ab.

Tabelle 4: Vergleich der Netzwerkeigenschaften von netTest und netControl.

Eigenschaft	netTest	netControl
Anzahl Knoten	16333	16333
Anzahl Kanten	117706	114537
Dichte	$8.825 \cdot 10^{-4}$	$8.588 \cdot 10^{-4}$
Durchmesser	2.04	1.73
Ø Knotengrad	14.41	14.03

erreicht werden. Der höchste Wert (0.54) trat bei $\beta_1 = 3$ auf (Abb. 18), sodass dieser Wert manuell als Soft-Threshold festgelegt wurde.




Abbildung 18: Erreichte R^2 -Werte für verschiedene mögliche Thresholds, eigene Abbildung. Die Zahlen im Diagramm stehen für das getestete Threshold («power»). Je weiter oben sie sich befinden, desto mehr erfüllen die mit ihnen erstellten Dissimilaritätsmatrizen (dissTOM) das Kriterium der Skalenfreiheit. Unerwartet war, dass keiner der Thresholds einen Wert über 0.54 erreichte, obwohl die Erwartung bei über 0.85 lag.

4.4 Wahl des Parameters cutHeight

„Modules vs cutHeight“ und „Median size vs cutHeight“ (Abb. 19) zeigen, dass sich die Modulstruktur im Bereich von etwa 0.94-0.96 stabilisierte. Oberhalb dieser Schwelle

blieb die Modulanzahl weitgehend konstant, während der zuvor dominante Grosscluster zerfiel und die mediane Modulgrösse abrupt abnahm. Beide Grössen veränderten sich in diesem Bereich nur noch gering, was auf eine **robuste** und biologisch gut interpretierbare **Clustereinteilung** hinweist. Auf Grundlage dieser Beobachtungen wurde eine Schritthöhe von 0.96 gewählt




Abbildung 19: Analyse des Einflusses der Schritthöhe, eigene Abbildung. Im Plot „Modules vs cutHeight“ zeigte sich ab einer Schritthöhe von etwa 0.94 bis 0.96 ein relatives Plateau, in dem die Anzahl der Module weitgehend stabil blieb, bei gleichzeitig noch akzeptabler Modulanzahl. Im Plot „Median size vs cutHeight“ hingegen trat bei etwa 0.93 ein markanter Sprung auf: Unterhalb dieser Schwelle dominierte ein sehr grosses Modul, während oberhalb viele kleine, differenzierte Module gebildet wurden.

4.5 Identifizierte differentiell koexprimierte Module

Mit der mit dem **TOM** berechneten Dissimilaritätsmatrix wurde eine **modulare Analyse** mittels hierarchischem Clustering durchgeführt. Das Verfahren **Dynamic Tree Cut** identifizierte dabei Gruppen von Genen mit ähnlichen differentiellen Koexpressionsmustern zwischen den Bedingungen. Insgesamt konnten sechs Module mit signifikanter differentieller Expression bestimmt werden (Tab. 5). Jedes Modul umfasst Gene, die deren Korrelation sich auf eine ähnliche Weise ändert ¹.

Die Module unterschieden sich sowohl in Grösse als auch in funktioneller Zusammensetzung. Beispiele sind das rote Modul, das u. a. CABP7 und CADM4 enthielt, das grüne Modul mit Genen wie ERRF1 und FOXD1 sowie das türkisfarbene Modul, das zahlreiche Gene aus der RNA-Polymerase-I/III-Familie umfasste (POLR1B, POLR3GL). Weitere Module (gelb, blau, braun) beinhalteten Gene mit potenziellen Funktionen in Signaltransduktion, Transportprozessen und Ubiquitin-vermittelter Regulation.

¹Achtung: Bei den hier besprochenen Modulen handelt es sich um diejenigen mit einer differentiellen Koexpression zwischen den Bedingungen (Test und Kontrolle), während es in Kapitel 4.2 um Module von Koexpression innerhalb einer Bedingung ging. Folglich sind die Farben aus Kapitel 4.2 und 4.5 gänzlich unverwandt.

Das resultierende **Dendrogramm** (Abb. 20) zeigt die hierarchische Gruppierung der Gene basierend auf ihren Differentialkoexpressionsprofilen. Die farbliche Markierung unterhalb der Zweige veranschaulicht die durch Dynamic Tree Cut identifizierten Module und erlaubt eine visuelle Zuordnung der Gencluster zu den jeweiligen Modulen. Gut erkennbar ist insbesondere, wie klein der Anteil von bedeutenden Genen (farbig dargestellt) im Vergleich zum unbedeutenden Anteil (grau) war.

Diese Module und deren Gencluster bildeten die Grundlage für die nachfolgende Anreicherungsanalyse zur Identifikation biologischer Prozesse, die durch die **VitD3**-Behandlung beeinflusst werden könnten.

Tabelle 5: Übersicht der identifizierten Module mit enthaltenen Genen.

Modulname (Farbe)	Enthaltene Gene (Gensymbole)	Modulgrösse
red	C6orf136 C7orf60 C9orf64 CABP7 CADM4	5
green	EPS8L1 ERRF1 FKBP14 FMR1NB FOXD1 NFXL1	6
turquoise	POLM POLR1B POLR1C POLR3GL POM121 POM121C POR POTE POU2AF1 PP2D1 PPFIA2 PPP1R15B	12
yellow	RHOV RHPN1 RILPL1 RIMS2 RMDN2 RNASE10 RNF24 RORB RP9	9
blue	SKP2 SLC10A2 SLC10A7 SLC16A11 SLC16A12 SLC17A7 SLC18A2 SLC1A4 SLC24A3 SLC25A13	10
brown	USP44 UTP23 UTRN UTS2 UTS2R UXT VAC14 VANG2 ZNF737	9

4.6 Überrepräsentierte Signalwege

Um die biologischen Funktionen der identifizierten Module näher zu charakterisieren, wurde eine **funktionelle Anreicherungsanalyse** durchgeführt. Dabei identifizierte die Analyse für jedes Modul die überrepräsentierten Signalwege und funktionellen Kategorien aus der **GO**. Aus den erhaltenen Ergebnissen wurden jeweils die drei Signalwege mit dem kleinsten adjustierten p-Wert ausgewählt ² (Tab. 6).

Das rote Modul zeigte eine deutliche Anreicherung von Signalwegen, die mit der **negativen Regulation der VEGF-Signalübertragung** und der **Peptidyl-Threonin-Phosphorylierung** assoziiert sind (alle $p = 0.006$). Diese Prozesse deuten auf eine

²Die vollständigen Enrichment-Ergebnisse sind auf Github unter “results/GO_enrichment_tables” auffindbar.




Abbildung 20: Dendrogramm mit Modulzuteilung, eigene Abbildung. Jede Linie stellt ein Modul dar. Auf der tiefsten Stufe haben diese Module die Grösse 1: Sie enthalten ein einziges Gen. Schneidet man das Dendrogramm hoch oben, entstehen grössere Module. Bei Height=2.5 beispielsweise werden alle vorhandenen Gene in zwei Module aufgeteilt, bereits bei der Höhe 2 hat man drei verschiedene Module. Je tiefer man die Schnitthöhe festsetzt, desto mehr Module erhält man, diese sind jedoch fortschreitend kleiner.

mögliche Beteiligung des Moduls an der Modulation zellulärer Signalaktivität und Gefässneubildung (Angiogenese) hin.

Im grünen Modul fanden sich unter anderem Gene mit Funktionen in der **T-Zell-Rezeptorbindung**, DNA-Biegung sowie GTPase-Regulatoraktivität ($p = 0.021$). Diese Befunde weisen auf eine potenzielle Rolle des Moduls in der Signaltransduktion und Transkriptionsregulation hin.

Das türkisfarbene Modul war stark mit Komponenten des **RNA- und DNA-Polymerase-Komplexes** sowie mit katalytischer Aktivität auf RNA assoziiert ($0.001 < p < 0.04$). Diese Anreicherungen deuten auf eine funktionelle Einbindung in die Transkription und RNA-Verarbeitung hin.

Für die gelben und braunen Module konnte keine signifikante funktionelle Anreicherung festgestellt werden, während das blaue Modul Gene mit **aktiver transmembraner Transportaktivität** enthielt ($p < 0.001$), darunter sekundäre aktive Transporter und Symporter.

Insgesamt zeigten die Ergebnisse, dass die durch Dynamic Tree Cut identifizierten Module klar unterschiedlichen biologischen Prozessen zugeordnet werden konnten.

4.7 Permutationstest

Aufgrund der Permutationsanalyse lässt sich schliessen, dass ausschliesslich das blaue, türkise und gelbe Modul von statistischer Signifikanz sind (Abb. 21).




Abbildung 21: Je dunkler der Bereich, desto signifikanter das entsprechende Modul. Somit sind blau, gelb und türkis von Bedeutung.

Tabelle 6: GO-Anreicherungsanalyse der identifizierten Module.

Modul	Beschreibung	Ontologie	p.adjust
red	negative regulation of vascular endothelial growth factor receptor signaling pathway	BP	0.006
	negative regulation of peptidyl-threonine phosphorylation	BP	0.006
	negative regulation of vascular endothelial growth factor signaling pathway	BP	0.006
green	T cell receptor binding	MF	0.021
	DNA binding, bending	MF	0.021
	GTPase regulator activity	MF	0.021
turquoise	RNA polymerase complex	CC	<0.001
	DNA polymerase activity	CC	<0.001
	catalytic activity, acting on RNA	CC	0.043
yellow	No significant enrichment		
blue	secondary active transmembrane transporter activity	MF	<0.001
	active transmembrane transporter activity	MF	<0.001
	symporter activity	MF	<0.001
brown	No significant enrichment		

4.8 Vergleich mit weiteren Datensets

Der Vergleich mit GSE55235 fand nur ein überschneidendes Gen: POU2AF1 (in der eigenen Analyse aus dem Modul “turquoise”). In GSE133426 gefundene DEGs hatten keinen Overlap.

5 Diskussion

In der vorliegenden Diskussion werden die zentralen **biologischen Ergebnisse** dieser Arbeit eingeordnet und im Kontext der **bestehenden Forschung** zu VitD3, T-Zell-Regulation und Rheumatoider Arthritis interpretiert. Besonderes Augenmerk liegt auf der Auswahl und Aussagekraft des verwendeten Datensatzes, der Bedeutung der mit DiffCoEx identifizierten Module sowie der biologischen Relevanz der angereicherten Signalwege. Anschliessend werden **methodische Entscheidungen und Limitationen**, insbesondere im Hinblick auf die Netzwerkanalyse und statistische Verfahren, kritisch reflektiert.

5.1 Die Wahl des Datensets

Die Analyse nutzte ein Datenset (GSE128816), das die Genexpression in T-Zellen erfasste, welche mit VitD3-tolDCs ko-kultiviert wurden. Dies war **keine intuitive Wahl** für die Erforschung des Effektes von **VitD3** auf **RA**, basierte allerdings auf mehreren methodischen und biologischen Überlegungen.

T-Zellen spielen eine **zentrale Rolle** in der Pathogenese der **RA** und anderer Autoimmunerkrankungen. Ein entscheidender Mechanismus zur Wiederherstellung der Immuntoleranz ist die Induktion von **T_{reg}S**. Es ist bekannt, dass **tolDCs** die Fähigkeit besitzen, naive T-Zellen in **T_{reg}**-Zellen zu differenzieren [70], [71], [72]. Ein gängiger und effektiver Ansatz zur Generierung von tolDCs in vitro ist die Behandlung mit VitD3. Das gewählte Datenset (GSE128816) nutzt genau diesen Mechanismus (Abb. 22).

TolDCs können auch durch **andere Stimuli** wie Retinsäure (Vitamin A) TGF- β induziert werden. Die resultierenden tolDC-Subtypen weisen allerdings **unterschiedliche molekulare Profile** und immunmodulatorische Eigenschaften auf. VitD3-induzierte tolDCs stellen dabei einen gut charakterisierten und häufig verwendeten tolDC-Typ dar, dessen Wirkmechanismen in der Regulation von T-Zellen und insbesondere in der Induktion von **T_{reg}**-Zellen **umfassend beschrieben** sind. Die Wahl eines Datensets, das explizit VitD3-induzierte tolDCs nutzt, ist daher sinnvoll, da es einen klar definierten und biologisch relevanten Signalweg repräsentiert.

Es muss angemerkt werden, dass das gewählte Datenset **nicht RA-spezifisch** war; die verwendeten Zellen stammen nicht von **RA**-Patienten. Die Relevanz von GSE128816 liegt jedoch darin, dass der untersuchte Mechanismus – die Modulation von T-Zellen durch tolDCs – einen fundamentalen Prozess abbildet, der bei der **RA** beeinträchtigt ist. Die Ergebnisse bieten daher Einblicke in grundlegende regulatorische Prozesse, die auf die **RA übertragbar** sind.




Abbildung 22: Reifung dendritischer Zellen, eigene Abbildung. Interagiert ein Pathogen mit einer unreifen dendritischen Zelle, differenziert zu einer reifen dendritischen Zelle (mDC). Wirkt jedoch VitD3 auf die unreife Zelle, wächst sie zu einer tolerogenen dendritischen Zelle (tolDC) heran.

Ein weiteres wesentliches Auswahlkriterium war die **Grösse des Datensets**. Die Genexpressionsanalyse in dieser Arbeit erforderte eine ausreichende Anzahl an Samples pro Behandlungsgruppe, um statistisch robuste und zuverlässige Ergebnisse zu erzielen [73]. Altay et al. (2023) schlugen für verlässliche Gennetzwerke **zwischen 30 und 85 Samples** vor [74]. Obwohl GSE128816 dieses Kriterium mit jeweils zehn Samples pro Gruppe nicht erfüllte, verbesserte das Bagging mit **BC3NET** die statistische Aussagekraft der Ergebnisse.

Schliesslich war zum Zeitpunkt der Recherche das analysierte Datenset das einzige **öffentlich verfügbare Set**, das die Kombination aus VitD3-Modulation, den **RA**-relevanten Immunzelltypen (T-Zellen und DCs) und einer vergleichsweise grossen Stichprobengrösse bot.

5.2 Die Bedeutung von DiffCoEx

Der Einsatz von DiffCoEx war notwendig, da eine gewöhnliche Clustersuche, die koexprimierte Gene in einem Zustand identifiziert, die hier relevante Dynamik nicht erfasst hätte. Wie in Abschnitt 3.6 dargelegt, verschiebt DiffCoEx die Analyseebene: Es fragt nicht, welche Gene “verbunden” sind, sondern welche Gene ihr “Verbindungsmuster auf dieselbe Weise ändern”. Der entscheidende Vorteil dieses Vorgehens war die Fähigkeit,

neben **Innerhalb-Modul-Änderungen** (Verlust des inneren Zusammenhalts) auch **Zwischen-Modul-Änderungen** (Verbindungsänderung eines Moduls zu anderen Modulen, ohne den eigenen inneren Zusammenhalt zu verlieren) zu erkennen. Letztere wären durch Standard-Koexpressionsanalysen unerkannt geblieben.

5.3 Biologische Interpretation der gefunden Pathways

5.3.1 Transkriptionelle Prozesse

Es zeigte sich eine signifikante Anreicherung von Signalwegen, die **transkriptionellen Mechanismen** zuzuordnen sind. Dazu gehörten fundamentale Mechanismen wie die Aktivität von RNA-Polymerase-Komplexen (I/III), die DNA-gerichtete RNA-Polymerase-Aktivität sowie generelle DNA-Bindungs- und Biegeprozesse. Im Modul “turquoise” wurden unter anderem die folgenden Pathways gefunden:

- “RNA polymerase complex”
- “DNA polymerase complex”
- “catalytic activity, acting on RNA”

Die Anreicherung dieser Kernprozesse der Genablesung ist ein starker Indikator für tiefgreifende Veränderungen in der Zellregulation. Dies lässt sich auf zwei Arten interpretieren:

Erstens könnte es eine **globale Herunterregulierung biosynthetischer Programme** widerspiegeln. Eine solche allgemeine Drosselung der Zellaktivität würde zu einem Zustand der **Hyporesponsivität** (verringerte Reaktionsfähigkeit) führen, was im Kontext der **RA** eine geringere Reaktion auf entzündliche Stimuli bedeuten würde. Navarro-Barriuso et al. (2021), die Autoren des in dieser Arbeit verwendeten Datensets, beobachteten diesen Effekt ebenfalls [38].

Zweitens könnte dies eine gezielte **Umgestaltung der transkriptionellen Kontrolle** anzeigen. Im Kontext der untersuchten T-Zellen deutet dieses Ergebnis darauf hin, dass nicht einfach alle Prozesse gehemmt, sondern stattdessen aktiv spezifische **regulatorische Programme** induziert werden. Diese Umprogrammierung der Genexpression ist ein plausibler Mechanismus, der der Entwicklung von naiven T-Zellen zu **T_{reg}**-Zellen durch Interaktion mit VitD3-tolDCs zugrunde liegen könnte.

5.3.2 Immunmetabolismus

Die im blauen Modul enthaltenen Gene sind an transmembraner Transportaktivität beteiligt. Dies könnte eine Rolle im sogenannten Immunmetabolismus spielen: Die metabolische Umprogrammierung von Immunzellen in verschiedenen Krankheitszuständen [75].

Wenn naive T-Zellen differenzieren, sind eine vergrößerte Biomasse und verstärkte Proliferation notwendig [75], beispielsweise ist der Glukose-Transporter (GLUT) hochreguliert [76]. **T_{reg}S** hingegen basieren ihren Stoffwechsel vor allem auf oxidativer Phosphorylierung.

rung (OXPHOS) [77]. RA ist durch ein proinflammatorisches Milieu geprägt, in dem Immunzellen wie Makrophagen und T-Zellen einen metabolischen Shift von der oxidativen Phosphorylierung (OXPHOS) hin zur aeroben Glykolyse vollziehen [78]. Durch die gezielte Beeinflussung der transmembranen Transportprozesse könnte Vitamin D3 also die metabolische Versorgung inflammatorischer Zellen drosseln und so deren Transition in einen antiinflammatorischen Zustand fördern.

5.3.3 Der Bezug zu Rheumatoider Arthritis

Zusammenfassend lässt sich festhalten, dass die Relevanz dieser Analyse für die Rheumatoide Arthritis in der Untersuchung zweier potentieller Toleranzinduktionsmechanismen lag. Das gewählte Datenset (GSE128816) modellierte exakt die Interaktion (VitD3-tolDCs und T-Zellen), die für die Wiederherstellung der Immuntoleranz, primär durch die Induktion von T_{reg} -Zellen, zentral sein könnte. Die Anwendung von DiffCoEx ermöglichte es, über die reine Koexpression hinauszublicken und die **dynamische Neuausrichtung der Gen-Interaktionen** zu erfassen, die dieser immunologischen Modulation zugrunde liegt.

Die Ergebnisse lieferten spezifische, auf die **RA**-Pathogenese übertragbare Einsichten:

1. Die tiefgreifende Umgestaltung **transkriptioneller Prozesse** (Modul “turquoise”) spiegelt die molekulare Basis für die Umprogrammierung von T-Zellen wider.
2. Die signifikante Anreicherung von Funktionen wie der sekundär-aktiven **Transmembran-Transporter- und Symporter-Aktivität** (Modul “blue”) deutet auf eine gezielte Regulation des Nährstoff- und Ionentransports hin. Da die RA-Pathogenese durch einen glykolytischen Shift und eine gestörte metabolische Homöostase in Immunzellen vorangetrieben wird, lässt die Beeinflussung dieser Transporter durch Vitamin D3 auf einen Mechanismus schließen, der proinflammatorische Effektorzellen energetisch drosselt und so deren Transition in einen hyporesponsiven Zustand begünstigt.

Diese Mechanismen (die Induktion eines regulatorischen T-Zell-Status sowie die Modulation metabolischer Signalwege) stellen zentrale Ansatzpunkte dar, um den pathologischen Prozessen der **RA** entgegenzuwirken. Die Analyse lieferte somit, trotz der Verwendung gesunder Spenderzellen, wertvolle Einblicke in die **therapeutisch relevanten Grundlagen** der immunologischen und metabolischen T-Zell-Modulation.

5.4 Methodische Überlegungen und Schwächen

5.4.1 Skalenfreie Topologie und der Parameter β_1

Das **Ausbleiben einer skalenfreien Topologie** im erstellten Netzwerk stellte allerdings dessen biologische Aussagekraft infrage. Ein möglicher Grund für diese Diskrepanz könnte in der Gradverteilung von netTest und netControl liegen. Die rot markierten Bereiche (Gene) in Abbildung 20 (Kap. 4.2) stimmen nicht mit dem Potenzgesetz überein. Eine

strengere Vorfilterung niedrig exprimierter Gene könnte die Topologie verbessern. Folglich ist es möglich, dass das hier generierte Netzwerk nicht die robuste, fehlertolerante Struktur repräsentierte, die für biologische Systeme erwartet wird. Die identifizierten Verbindungen und Module könnten daher **weniger aussagekräftig** sein. Zukünftige Analysen sollten insbesondere die erstellten Netzwerke vor der Anwendung von DiffCoEx systematisch neu bewerten, um den R^2 -Wert für die skalenfreie Topologie zu maximieren und so die biologische Relevanz des Modells zu verbessern.

5.4.2 Transformation und Verteilungsproblematik

Die **log2-Transformation** spreizte den Wertebereich erfolgreich, sodass relevante Signalunterschiede deutlicher hervortraten (Abb. 14b). Eine annähernde Normalverteilung zeigte sich jedoch erst ab einem Wert von ca. $x = 7$, während bei $x = 0$ ein lokales Maximum (Häufung niedriger Intensitäten) bestehen blieb. Diese Abweichung ist problematisch, da der **BC3NET**-Algorithmus eine **Normalverteilung voraussetzt**. Die Überrepräsentation niedriger Werte könnte die Schätzung der Zufallsverteilung verzerren: Es besteht das Risiko, dass schwach gestützte Kanten fälschlicherweise als signifikant eingestuft (Überschätzung des Rauschens) und echte Zusammenhänge in normalverteilten Bereichen unterschätzt werden. Dies mindert die Trennschärfe und könnte die **Netzwerkstruktur verfälschen**.

5.4.3 Normalisierung

Die anschliessende **Quantilnormalisierung** trug jedoch wesentlich zur Vereinheitlichung der Signalverteilungen bei. Der über weite Strecken lineare Verlauf des Q-Q-Plots belegt eine **erfolgreiche Angleichung** der empirischen an die theoretische Verteilung (Abb. 15b). Damit wurden technische Varianzen zwischen den Arrays reduziert und die Vergleichbarkeit der Proben sichergestellt. Die Abflachung im linken Bereich des Plots (bei $x < 0$) deutet auf eine **starke Komprimierung** sehr niedriger Intensitätswerte hin. Dieser Informationsverlust ist **methodisch akzeptabel**, da er die Reproduzierbarkeit in den biologisch relevanteren mittleren und höheren Bereichen verbessert. Zusätzlich zur Quantilnormalisierung sollte eine Korrektur möglicher Batch-Effekte in Betracht gezogen werden. Systematische Unterschiede zwischen den Versuchsgruppen könnten sonst die Expressionswerte verzerren und zu falschen biologischen Schlussfolgerungen führen [79].

5.4.4 Die Wahl der Schnitthöhe im hierarchischen Clustering

Die Auswahl der Schnitthöhe (cutHeight) im hierarchischen Clustering bestimmt massgeblich die resultierende Modulstruktur, da sie festlegt, bis zu welchem **Ähnlichkeitsgrad** Gene zu einem gemeinsamen Cluster zusammengefasst werden. Eine zu niedrige Schnitthöhe führt typischerweise zu einer Überfragmentierung des Netzwerks in zahlreiche kleine Cluster, während eine zu hohe Schwelle dazu neigt, funktionell heterogene Gene in wenigen grossen Modulen zusammenzufassen. Die Schnitthöhe von 0.96 stellte einen sinnvollen

Kompromiss zwischen Kohärenz und Modulgranularität dar. Diese Schwelle vermied sowohl die Bildung eines dominanten, biologisch schwer interpretierbaren Grossmoduls als auch eine übermässige Fragmentierung in zahlreiche Kleinstmodule. Obwohl diese Entscheidung empirisch ist, wies die Stabilität der Modulstruktur in benachbarten Bereichen (0.95-0.97) auf eine robuste und konsistente Clusterbildung hin.

5.4.5 Der Vergleich mit weiteren Datensets

Es konnten keine signifikanten Überschneidungen mit den zwei weiteren untersuchten Datensets gefunden werden. Dies könnte darauf hindeuten, dass

- (A) die gefundenen Module **zufällig entstanden** sind und keine biologische Relevanz besitzen. Dagegen spricht, dass die Anreicherung ihnen **signifikante biologische Signalwege** zuordnen konnte.
- (B) die Methode DiffCoEx sucht von sich aus nach einer **anderen Art von Genänderung**, als die gängige DEG-Analyse. Dass die Gene also nicht übereinstimmen, macht Sinn: Sie sind auf andere Art beteiligt.

Ein Vergleich mit den Netzwerkstrukturen und DiffCoEx (anstatt den DEGs) anderer Datensätze könnte also Hinweise darauf liefern, wie robust DiffCoEx Module identifiziert.

5.5 Vergleichbarkeit und Reproduzierbarkeit

Ein zentrales Anliegen dieser Arbeit war, reproduzierbare Ergebnisse und vor allem **nachvollziehbare Methoden** bereitzustellen. Viele der wissenschaftlichen Publikationen, die im Rahmen der Recherche konsultiert wurden, erwiesen sich als nur eingeschränkt reproduzierbar: Teilweise war der Code fest an einen spezifischen Datensatz gebunden, teilweise wurde er überhaupt nicht offengelegt. Daher wurden für diese Arbeit sämtliche Analyseschritte vollständig auf **GitHub** dokumentiert, sodass sie transparent eingesehen und bei Bedarf erneut ausgeführt werden können.

Zum verwendeten Algorithmus **BC3NET** ist eine Anmerkung erforderlich: Da **BC3NET** auf Bootstrap-Aggregation basiert, ist das Verfahren **stochastisch** und kann bei wiederholten Durchläufen leicht unterschiedliche Netzwerke generieren. Diese **Variabilität** erschwert direkte Vergleiche zwischen einzelnen Ergebnissen, reflektiert jedoch gleichzeitig die inhärente Unsicherheit in den zugrunde liegenden Daten. Eine **grössere Anzahl an Bootstraps** könnte die Stabilität und Reproduzierbarkeit der Ergebnisse erhöhen.

Die Arbeit führte **mehrere unabhängige BC3NET-Analysen** durch, um die Robustheit der Ergebnisse zu überprüfen. Dabei fiel eine unerwartete **Diskrepanz** zwischen zwei Berechnungsvarianten auf: In einem Fall wurde innerhalb der Funktion `bc3net()` ein `igraph`-Objekt erzeugt (`igraph=TRUE`) und anschliessend in eine Adjazenzmatrix konvertiert; im anderen Fall wurde direkt eine Adjazenzmatrix erstellt (`igraph=FALSE`).

Trotz identischer Eingabedaten führten diese beiden Ansätze zu unterschiedlichen Netzwerkstrukturen.

Zudem zeigten sich deutliche Unterschiede in der Rechenleistung zwischen **Betriebssystemen**. Während Windows-Systeme `bc3net(igraph=TRUE)` innerhalb von etwa 24 Stunden erfolgreich ausführten, konnte auf macOS-Systemen die Berechnung aufgrund von **Speicherlimitierungen** nicht abgeschlossen werden. Umgekehrt verlief die Berechnung mit `igraph=FALSE` auf Macs deutlich schneller (ca. 2 Stunden) als auf Windows-Rechnern. Für die Analysen wurden daher die Netzwerke verwendet, die auf dem Windows-System mit `igraph=TRUE` erzeugt wurden, da diese Variante konsistent mit der **Originalimplementierung** des **BC3NET**-Workflows ist. Künftige Arbeiten könnten systematisch untersuchen, ob die beobachteten Unterschiede durch betriebssystemspezifische Speicherverwaltung, Bibliotheksversionen oder Unterschiede in der parallelen Verarbeitung bedingt sind. Eine **Wiederholung der Analyse unter Linux** wäre ein geeigneter Ansatz, um diese technische Unsicherheit weiter zu minimieren.

5.6 Ausblick

Zusammenfassend sind die **identifizierten Module biologisch plausibel** und stimmen mit der Literatur überein. Sie sind jedoch aufgrund der genannten methodischen Einschränkungen **explorativ** zu verstehen.

Zukünftige Arbeiten könnten auf dieser Analyse aufbauen, indem sie grössere, **RA-spezifische Datensätze** verwenden und die Effekte von VitD3 auf **DCs** vertieft untersuchen. Die **experimentelle Validierung** der identifizierten Signalwege, idealerweise direkt an Proben von **RA**-Patienten, könnte die Relevanz der Befunde untermauern. Methodisch sollte darauf geachtet werden, eine skalenfreie Netzwerktopologie zu erhalten, die Datenverarbeitung zu optimieren und die gewählten Parameter mittels Permutationstests zu validieren. Angesichts der begrenzten Robustheit der aktuellen R-Implementierung von **BC3NET** könnte zudem der Einsatz **alternativer Inferenzmethoden** die Stabilität und Zuverlässigkeit der Ergebnisse verbessern.

6 Fazit

Diese Arbeit untersuchte, wie Vitamin-D3-behandelte tolerogene dendritische Zellen die Gen-Koexpressionsnetzwerke von T-Zellen beeinflussen. Mittels der Algorithmen **BC3NET** und DiffCoEx wurden differenziell aktive Genmodule identifiziert. Die biologische Auswertung deutet auf eine Beeinflussung wichtiger Signalwege hin, darunter die **Regulation des Immunmetabolismus** und die **transkriptionellen Prozesse**. Diese Ergebnisse stützen die immunmodulatorische Rolle von **VitD3** und bieten potenzielle Ansatzpunkte für Therapien. Die Aussagekraft ist durch wesentliche methodische Limitationen eingeschränkt. Insbesondere erreichte das konstruierte Netzwerk keine skalenfreie Topologie, was dessen biologische Relevanz infrage stellt; gleichzeitig war das Datenset nicht **RA**-spezifisch. Zukünftige Forschung muss daher die Methodik verbessern:

1. Es sollte ein geeigneteres Datenset benutzt und die Normalisierung sollte um eine Batch-Effekt-Korrektur ergänzt werden.
2. Die Netzwerk-Konstruktion muss optimiert werden, um eine skalenfreie Topologie zu erreichen.
3. Möglicherweise sollte eine alternative Methode zu **BC3NET** gefunden werden.

Der nächste Schritt ist die **experimentelle Validierung** der bioinformatischen Hypothesen. Insbesondere die funktionelle Relevanz der identifizierten Signalwege könnte im Labor überprüft werden.

Beiträge

Name	E-Mail	Beitrag
Dr. Tim Roloff	troloff@imm.uzh.ch	Experte beim Nationalen Wettbewerb von Schweizer Jugend Forscht
Dr. Izaskun Mallona	izaskun.mallona@mls.uzh.ch	Mentoring und Anleitung zur Erstellung von Gennetzwerken, Korrekturlesen
Dr. Patrick Aschwanden	patrick.aschwanden@edu.kzn.ch	Betreuungsperson in der Schule
Prof. Dr. Dr. Caroline Ospelt	caroline.ospelt@usz.ch	Hilfe bei der Definition der Forschungsfrage
Prof. Dr. Amedeo Caf-lisch	caflisch@bioc.uzh.ch	Hilfe bei der Eingrenzung des Themas

Verwendung generativer KI

Gemäss den Richtlinien für den Nationalen Wettbewerb von Schweizer Jugend Forscht werden hier die verschiedenen Anwendungen von generativen KI-Tools in diesem Projekt transparent dargelegt. Grundsätzlich wurde KI ausschliesslich als unterstützendes Werkzeug eingesetzt. Alle generierten Inhalte wurden sorgfältig auf ihre Richtigkeit überprüft, mit Quellen abgeglichen und grundlegend überarbeitet.

- **Ideenfindung:** ChatGPT 5 wurde zur Evaluation von Forschungsansätzen, zur Ermittlung von Suchbegriffen für Fachdatenbanken und zur Identifikation von Wissenslücken genutzt.
- **Verständnis von Fachliteratur:** ChatGPT half ebenfalls dabei, komplexe wissenschaftliche Publikationen auf ihre Kernaussagen zu reduzieren, um gezielte Recherchen zu erleichtern.
- **Textbearbeitung:** Gemini 2.5 Pro diente der sprachlichen Überarbeitung von Textabschnitten. Zudem wurden aus eigenen Zusammenfassungen Textentwürfe generiert, die anschliessend manuell weiterverarbeitet wurden.
- **Code-Entwicklung:** Claude (Sonnet 4.5) wurde für die Erstellung, Fehlersuche und Optimierung von Code konsultiert. Ergänzend kam GitHub Copilot (Education) in RStudio zur Code-Annotation und beschleunigten Entwicklung zum Einsatz.
- **Abbildungsqualität:** IMGUpscaler wurde verwendet, um die Qualität von Abbildungen zu verbessern, ohne den Inhalt zu verändern.

Literatur

- [1] *Induktion Tolerogener Dendritischer Zellen*, 2015. Adresse: https://epub.uni-regensburg.de/31977/1/Promotion_epub_MP_21.06.2015.pdf
- [2] D. Eckebrecht, „Immunbiologie,“ in *Natura 9-12: Grundlagen Der Biologie Für Schweizer Maturitätsschulen*, 5. Auflage (unveränderter Nachdruck der 1. Auflage 2018), Klett und Balmer Verlag, ISBN: 978-3-264-84038-4.
- [3] M. Bscheider und E. C. Butcher, „Vitamin D immunoregulation through dendritic cells,“ *Immunology*, Jg. 148, Nr. 3, S. 227–236, 2016, ISSN: 1365-2567. DOI: [10.1111/imm.12610](https://doi.org/10.1111/imm.12610) besucht am 30. Okt. 2025. Adresse: <https://onlinelibrary.wiley.com/doi/abs/10.1111/imm.12610>
- [4] D. Eckebrecht, „Anatomie Und Physiologie Der Lebewesen,“ in *Natura 9-12: Grundlagen Der Biologie Für Schweizer Maturitätsschulen*, 5. Auflage (unveränderter Nachdruck der 1. Auflage 2018), Klett und Balmer Verlag, ISBN: 978-3-264-84038-4.
- [5] „Rheumatoid Arthritis: Severity Classification, Factors Responsible, Pathophysiology, Current and Herbal Treatment,“ in *Rheumatoid Arthritis*, S. T. Galatage, Hrsg., IntechOpen, 19. Jan. 2022, ISBN: 978-1-83969-671-8 978-1-83969-672-5. DOI: [10.5772/intechopen.95728](https://doi.org/10.5772/intechopen.95728) besucht am 10. Apr. 2025. Adresse: <https://www.intechopen.com/books/11031>
- [6] R. Moura und J. Fonseca, „B Cells on the Stage of Inflammation in Juvenile Idiopathic Arthritis: Leading or Supporting Actors in Disease Pathogenesis?“ *Frontiers in Medicine*, Jg. 9, Apr. 2022. DOI: [10.3389/fmed.2022.851532](https://doi.org/10.3389/fmed.2022.851532)
- [7] D. A. Walsh, „Angiogenesis and Arthritis,“ *Rheumatology*, Jg. 38, Nr. 2, S. 103–112, 1. Feb. 1999, ISSN: 1462-0324. DOI: [10.1093/rheumatology/38.2.103](https://doi.org/10.1093/rheumatology/38.2.103) besucht am 30. Okt. 2025. Adresse: <https://doi.org/10.1093/rheumatology/38.2.103>
- [8] P. C. Taylor, „VEGF and Imaging of Vessels in Rheumatoid Arthritis,“ *Arthritis Research*, Jg. 4, S99–S107, Suppl 3 2002, ISSN: 1465-9905. DOI: [10.1186/ar582](https://doi.org/10.1186/ar582) PMID: [12110128](https://pubmed.ncbi.nlm.nih.gov/12110128/). besucht am 30. Okt. 2025. Adresse: <https://pmc.ncbi.nlm.nih.gov/articles/PMC3240157/>
- [9] *Fibroblast*, in *Wikipedia*, 16. Dez. 2023. besucht am 22. Okt. 2025. Adresse: <https://de.wikipedia.org/w/index.php?title=Fibroblast&oldid=240247939>
- [10] *Grundlagen Der Genetik*, 2014. besucht am 7. Okt. 2025. Adresse: https://www.ernaehrungs-umschau.de/fileadmin/Ernaehrungs-Umschau/pdfs/pdf_2014/05_14/EU05_2014_M258_M265.pdf

- [11] D. Eckebrecht, „Genetik,“ in *Natura 9-12: Grundlagen Der Biologie Für Schweizer Maturitätsschulen*, 5. Auflage (unveränderter Nachdruck der 1. Auflage 2018), Klett und Balmer Verlag, ISBN: 978-3-264-84038-4.
- [12] Y. Zhao, C. V. Forst, C. E. Sayegh, I.-M. Wang, X. Yang und B. Zhang, „Molecular and Genetic Inflammation Networks in Major Human Diseases,“ *Molecular bioSystems*, Jg. 12, Nr. 8, S. 2318–2341, 19. Juli 2016, ISSN: 1742-206X. DOI: [10.1039/c6mb00240d](https://doi.org/10.1039/c6mb00240d) PMID: [27303926](https://pubmed.ncbi.nlm.nih.gov/27303926/). besucht am 14. Okt. 2025. Adresse: <https://pmc.ncbi.nlm.nih.gov/articles/PMC4955784/>
- [13] K. Kuchta u. a., „Predicting proteome dynamics using gene expression data,“ *Scientific Reports*, Jg. 8, Nr. 1, S. 13866, 14. Sep. 2018, ISSN: 2045-2322. DOI: [10.1038/s41598-018-31752-4](https://doi.org/10.1038/s41598-018-31752-4) besucht am 7. Okt. 2025. Adresse: <https://www.nature.com/articles/s41598-018-31752-4>
- [14] G. Sanguinetti und V. A. Huynh-Thu, *Gene Regulatory Networks: Methods and Protocols* (Springer Protocols). 2019.
- [15] K. P. Singh, C. Miaskowski, A. A. Dhruva, E. Flowers und K. M. Kober, „Mechanisms and Measurement of Changes in Gene Expression,“ *Biological Research for Nursing*, Jg. 20, Nr. 4, S. 369–382, Juli 2018, ISSN: 1099-8004. DOI: [10.1177/1099800418772161](https://doi.org/10.1177/1099800418772161) PMID: [29706088](https://pubmed.ncbi.nlm.nih.gov/29706088/). besucht am 6. Aug. 2025. Adresse: <https://www.ncbi.nlm.nih.gov/pmc/articles/PMC6346310/>
- [16] *Gensonde*, in *Wikipedia*, 19. März 2025. besucht am 22. Okt. 2025. Adresse: <https://de.wikipedia.org/w/index.php?title=Gensonde&oldid=254345203>
- [17] „Network Analysis and Visualization with R and Igraph,“ besucht am 8. Okt. 2025. Adresse: <https://kateto.net/netscix2016.html>
- [18] Y. Uzun, *Approaches for Benchmarking Single-Cell Gene Regulatory Network Inference Methods*. 17. Juli 2023. DOI: [10.48550/arXiv.2307.08463](https://doi.org/10.48550/arXiv.2307.08463)
- [19] EMBL-EBI. „Graph theory: Adjacency matrices | Network analysis of protein interaction data,“ besucht am 15. Nov. 2025. Adresse: <https://www.ebi.ac.uk/training/online/courses/network-analysis-of-protein-interaction-data-an-introduction/introduction-to-graph-theory/graph-theory-adjacency-matrices/>
- [20] B. Zhang und S. Horvath, „A General Framework for Weighted Gene Co-Expression Network Analysis,“ *Statistical Applications in Genetics and Molecular Biology*, Jg. 4, Nr. 1, 12. Jan. 2005, ISSN: 1544-6115, 2194-6302. DOI: [10.2202/1544-6115.1128](https://doi.org/10.2202/1544-6115.1128) besucht am 19. Okt. 2025. Adresse: <https://www.degruyter.com/document/doi/10.2202/1544-6115.1128/html>
- [21] E. Almaas, A. Vazquez und A.-L. Barabasi, „Scale-Free Networks in Biology,“ *Biological networks*, Jg. 3, 9. Jan. 2013, ISSN: 978-981-270-695-9. DOI: [10.1142/9789812772367_0001](https://doi.org/10.1142/9789812772367_0001)

- [22] *Scale-free network*, in *Wikipedia*, 5. Okt. 2025. besucht am 25. Okt. 2025. Adresse: https://en.wikipedia.org/w/index.php?title=Scale-free_network&oldid=1315229129
- [23] S. Bergmann, J. Ihmels und N. Barkai, „Similarities and differences in genome-wide expression data of six organisms“, *PLoS biology*, Jg. 2, Nr. 1, E9, Jan. 2004, ISSN: 1545-7885. DOI: [10.1371/journal.pbio.0020009](https://doi.org/10.1371/journal.pbio.0020009) PMID: [14737187](https://pubmed.ncbi.nlm.nih.gov/14737187/).
- [24] H. Jeong, B. Tombor, R. Albert, Z. N. Oltvai und A. L. Barabási, „The large-scale organization of metabolic networks“, *Nature*, Jg. 407, Nr. 6804, S. 651–654, 5. Okt. 2000, ISSN: 0028-0836. DOI: [10.1038/35036627](https://doi.org/10.1038/35036627) PMID: [11034217](https://pubmed.ncbi.nlm.nih.gov/11034217/).
- [25] B. M. Tesson, R. Breitling und R. C. Jansen, „DiffCoEx: A Simple and Sensitive Method to Find Differentially Coexpressed Gene Modules“, *BMC Bioinformatics*, Jg. 11, Nr. 1, S. 497, 6. Okt. 2010, ISSN: 1471-2105. DOI: [10.1186/1471-2105-11-497](https://doi.org/10.1186/1471-2105-11-497) besucht am 23. Aug. 2025. Adresse: <https://doi.org/10.1186/1471-2105-11-497>
- [26] C. Olsen, P. E. Meyer und G. Bontempi, „On the Impact of Entropy Estimation on Transcriptional Regulatory Network Inference Based on Mutual Information“, *EURASIP Journal on Bioinformatics and Systems Biology*, Jg. 2009, Nr. 1, S. 308959, 26. Nov. 2008, ISSN: 1687-4145. DOI: [10.1155/2009/308959](https://doi.org/10.1155/2009/308959) PMID: [19148299](https://pubmed.ncbi.nlm.nih.gov/19148299/). besucht am 31. Okt. 2025. Adresse: <https://pmc.ncbi.nlm.nih.gov/articles/PMC3171423/>
- [27] *Spearman's rank correlation coefficient*, in *Wikipedia*, 1. Okt. 2025. besucht am 31. Okt. 2025. Adresse: https://en.wikipedia.org/w/index.php?title=Spearman's_rank_correlation_coefficient&oldid=1314372934
- [28] *Ranking (statistics)*, in *Wikipedia*, 10. Juni 2025. besucht am 31. Okt. 2025. Adresse: [https://en.wikipedia.org/w/index.php?title=Ranking_\(statistics\)&oldid=1294851829](https://en.wikipedia.org/w/index.php?title=Ranking_(statistics)&oldid=1294851829)
- [29] *Pearson correlation coefficient*, in *Wikipedia*, 30. Okt. 2025. besucht am 31. Okt. 2025. Adresse: https://en.wikipedia.org/w/index.php?title=Pearson_correlation_coefficient&oldid=1319520508
- [30] „Pearson Correlation - an Overview | ScienceDirect Topics“, besucht am 31. Okt. 2025. Adresse: <https://www.sciencedirect.com/topics/computer-science/pearson-correlation>
- [31] V. Demberg, „Mathematische Grundlagen III - Informationstheorie“, 2012.
- [32] R. d. M. Simoes und F. Emmert-Streib, „Bagging Statistical Network Inference from Large-Scale Gene Expression Data“, *PLOS ONE*, Jg. 7, Nr. 3, e33624, 30. März 2012, ISSN: 1932-6203. DOI: [10.1371/journal.pone.0033624](https://doi.org/10.1371/journal.pone.0033624) besucht am 11. Aug. 2025. Adresse: <https://journals.plos.org/plosone/article?id=10.1371/journal.pone.0033624>
- [33] A. J. Butte, „Mutual Information Relevance Networks: Functional Genomic Networks Built From Pair-wise Entropy Measurements“, 2002.

- [34] M. bei DocCheck. „Nullhypothese,“ DocCheck Flexikon, besucht am 19. Nov. 2025. Adresse: <https://flexikon.doccheck.com/de/Nullhypothese>
- [35] S. Turney. „Nullhypothese: Definition, Alternativhypothese, Beispiele,“ Scribbr, besucht am 19. Nov. 2025. Adresse: <https://www.scribbr.ch/statistik-ch/nullhypothese/>
- [36] *Bernoulli-Prozess*, in *Wikipedia*, 13. Dez. 2024. besucht am 19. Nov. 2025. Adresse: <https://de.wikipedia.org/w/index.php?title=Bernoulli-Prozess&oldid=251205110>
- [37] „GEO Accession Viewer,“ besucht am 14. Okt. 2025. Adresse: <https://www.ncbi.nlm.nih.gov/geo/query/acc.cgi?acc=GSE128816>
- [38] J. Navarro-Barriuso, M. J. Mansilla, B. Quirant-Sánchez, A. Teniente-Serra, C. Ramo-Tello und E. M. Martínez-Cáceres, „Vitamin D3-Induced Tolerogenic Dendritic Cells Modulate the Transcriptomic Profile of T CD4+ Cells Towards a Functional Hyporesponsiveness,“ *Frontiers in Immunology*, Jg. 11, S. 599 623, 2020, ISSN: 1664-3224. DOI: [10.3389/fimmu.2020.599623](https://doi.org/10.3389/fimmu.2020.599623) PMID: [33552054](https://pubmed.ncbi.nlm.nih.gov/33552054/).
- [39] G. Zinman, „Microarray normalization,“ S. 80, besucht am 31. Okt. 2025. Adresse: <https://doi.org/10.1186/s13075-022-02803-z>
- [40] C. Workman u. a., „A new non-linear normalization method for reducing variability in DNA microarray experiments,“ *Genome Biology*, Jg. 3, Nr. 9, research0048.1, 30. Aug. 2002, ISSN: 1474-760X. DOI: [10.1186/gb-2002-3-9-research0048](https://doi.org/10.1186/gb-2002-3-9-research0048) besucht am 31. Okt. 2025. Adresse: <https://genomebiology.biomedcentral.com/articles/10.1186/gb-2002-3-9-research0048>
- [41] „R: The R Project for Statistical Computing,“ besucht am 26. Okt. 2025. Adresse: <https://www.r-project.org/>
- [42] „Posit | The Open-Source Data Science Company,“ Posit, besucht am 26. Okt. 2025. Adresse: <https://posit.co/>
- [43] R. d. M. Simoes und F. Emmert-Streib, *Bc3net: Gene Regulatory Network Inference with Bc3net*, Version 1.0.5, 6. Mai 2025. besucht am 26. Okt. 2025. Adresse: <https://cran.r-project.org/web/packages/bc3net/index.html>
- [44] P. Langfelder und S. Horvath, „WGCNA: An R Package for Weighted Correlation Network Analysis,“ *BMC Bioinformatics*, Jg. 9, Nr. 1, S. 559, 29. Dez. 2008, ISSN: 1471-2105. DOI: [10.1186/1471-2105-9-559](https://doi.org/10.1186/1471-2105-9-559) besucht am 26. Okt. 2025. Adresse: <https://doi.org/10.1186/1471-2105-9-559>
- [45] E. Neuwirth, *RColorBrewer: ColorBrewer Palettes*, Version 1.1-3, 3. Apr. 2022. besucht am 26. Okt. 2025. Adresse: <https://cran.r-project.org/web/packages/RColorBrewer/index.html>
- [46] „preprocessCore,“ Bioconductor, besucht am 26. Okt. 2025. Adresse: <http://bioconductor.org/packages/preprocessCore/>

- [47] G. Csárdi u. a., *Igraph: Network Analysis and Visualization*, Version 2.2.0, 13. Okt. 2025. besucht am 26. Okt. 2025. Adresse: <https://cran.r-project.org/web/packages/igraph/index.html>
- [48] P. L. a. S. Horvath, *moduleColor: Basic Module Functions*, Version 1.8-4, 9. Apr. 2022. besucht am 26. Okt. 2025. Adresse: <https://cran.r-project.org/web/packages/moduleColor/index.html>
- [49] H. Wickham, T. L. Pedersen, D. Seidel, P. Software, P. [cph und fnd, *Scales: Scale Functions for Visualization*, Version 1.4.0, 24. Apr. 2025. besucht am 26. Okt. 2025. Adresse: <https://cran.r-project.org/web/packages/scales/index.html>
- [50] H. Wickham u. a., *Dplyr: A Grammar of Data Manipulation*, Version 1.1.4, 17. Nov. 2023. besucht am 26. Okt. 2025. Adresse: <https://cran.r-project.org/web/packages/dplyr/index.html>
- [51] „Create Elegant Data Visualisations Using the Grammar of Graphics,“ besucht am 26. Okt. 2025. Adresse: <https://ggplot2.tidyverse.org/>
- [52] P. Langfelder und S. Horvath, „Fast R Functions for Robust Correlations and Hierarchical Clustering,“ *Journal of Statistical Software*, Jg. 46, S. 1–17, 7. März 2012, ISSN: 1548-7660. DOI: [10.18637/jss.v046.i11](https://doi.org/10.18637/jss.v046.i11) besucht am 26. Okt. 2025. Adresse: <https://doi.org/10.18637/jss.v046.i11>
- [53] G. Yu, L.-G. Wang, Y. Han und Q.-Y. He, „clusterProfiler: An R package for comparing biological themes among gene clusters,“ *Omics: A Journal of Integrative Biology*, Jg. 16, Nr. 5, S. 284–287, Mai 2012, ISSN: 1557-8100. DOI: [10.1089/omi.2011.0118](https://doi.org/10.1089/omi.2011.0118) PMID: [22455463](https://pubmed.ncbi.nlm.nih.gov/22455463/).
- [54] „Org.Hs.eg.db,“ Bioconductor, besucht am 26. Okt. 2025. Adresse: <http://bioconductor.org/packages/org.Hs.eg.db/>
- [55] „Enrichplot,“ Bioconductor, besucht am 26. Okt. 2025. Adresse: <http://bioconductor.org/packages/enrichplot/>
- [56] M. West, „Bayesian Factor Regression Models in the “Large p, Small n” Paradigm,“ in *Bayesian Statistics 7*, V. Lindley u. a., Hrsg., Oxford University Press Oxford, 3. Juli 2003, S. 733–742, ISBN: 978-0-19-852615-5 978-1-383-02433-3. DOI: [10.1093/oso/9780198526155.003.0053](https://academic.oup.com/book/54032/chapter/422208414) besucht am 31. Okt. 2025. Adresse: <https://academic.oup.com/book/54032/chapter/422208414>
- [57] J. L. Horowitz, „Bootstrap Methods in Econometrics,“ *Annual Review of Economics*, Jg. 11, S. 193–224, Volume 11, 2019 2. Aug. 2019, ISSN: 1941-1383, 1941-1391. DOI: [10.1146/annurev-economics-080218-025651](https://doi.org/10.1146/annurev-economics-080218-025651) besucht am 31. Okt. 2025. Adresse: <https://www.annualreviews.org/content/journals/10.1146/annurev-economics-080218-025651>

- [58] P. Bůžková, T. Lumley und K. Rice, „Permutation and Parametric Bootstrap Tests for Gene—Gene and Gene—Environment Interactions,“ *Annals of human genetics*, Jg. 75, Nr. 1, S. 36–45, Jan. 2011, ISSN: 0003-4800. DOI: [10.1111/j.1469-1809.2010.00572.x](https://doi.org/10.1111/j.1469-1809.2010.00572.x) PMID: [20384625](https://pubmed.ncbi.nlm.nih.gov/20384625/). besucht am 7. Okt. 2025. Adresse: <https://pmc.ncbi.nlm.nih.gov/articles/PMC2904826/>
- [59] *Binomialverteilung*, in *Wikipedia*, 17. Okt. 2025. besucht am 19. Nov. 2025. Adresse: <https://de.wikipedia.org/w/index.php?title=Binomialverteilung&oldid=260675866>
- [60] V. D. Blondel, J.-L. Guillaume, R. Lambiotte und E. Lefebvre, „Fast unfolding of communities in large networks,“ *Journal of Statistical Mechanics: Theory and Experiment*, Jg. 2008, Nr. 10, P10008, Okt. 2008, ISSN: 1742-5468. DOI: [10.1088/1742-5468/2008/10/P10008](https://doi.org/10.1088/1742-5468/2008/10/P10008) besucht am 31. Okt. 2025. Adresse: <https://doi.org/10.1088/1742-5468/2008/10/P10008>
- [61] *Louvain method*, in *Wikipedia*, 29. Sep. 2025. besucht am 17. Nov. 2025. Adresse: https://en.wikipedia.org/w/index.php?title=Louvain_method&oldid=1314054933
- [62] „The DrL graph layout generator — layout_with_drl,“ besucht am 17. Nov. 2025. Adresse: https://r.igraph.org/reference/layout_with_drl.html
- [63] G. Stulp, *Chapter 5 Layouts / Network Data Visualisation in R – The Patio*. besucht am 20. Nov. 2025. Adresse: <https://stulp.gmw.rug.nl/patio/layoutt.html>
- [64] G. Yu, *Chapter 5 Overview of Enrichment Analysis / Biomedical Knowledge Mining Using GOSemSim and clusterProfiler*. 2022. besucht am 15. Okt. 2025. Adresse: <https://yulab-smu.top/biomedical-knowledge-mining-book/enrichment-overview.html>
- [65] E. I. Boyle u. a., „GO::TermFinder—open source software for accessing Gene Ontology information and finding significantly enriched Gene Ontology terms associated with a list of genes,“ *Bioinformatics (Oxford, England)*, Jg. 20, Nr. 18, S. 3710–3715, 12. Dez. 2004, ISSN: 1367-4803. DOI: [10.1093/bioinformatics/bth456](https://doi.org/10.1093/bioinformatics/bth456) PMID: [15297299](https://pubmed.ncbi.nlm.nih.gov/15297299/).
- [66] D. W. Huang, B. T. Sherman und R. A. Lempicki, „Bioinformatics Enrichment Tools: Paths toward the Comprehensive Functional Analysis of Large Gene Lists,“ *Nucleic Acids Research*, Jg. 37, Nr. 1, S. 1–13, Jan. 2009, ISSN: 0305-1048. DOI: [10.1093/nar/gkn923](https://doi.org/10.1093/nar/gkn923) PMID: [19033363](https://pubmed.ncbi.nlm.nih.gov/19033363/). besucht am 15. Okt. 2025. Adresse: <https://pmc.ncbi.nlm.nih.gov/articles/PMC2615629/>
- [67] „Gene Ontology Overview,“ Gene Ontology Resource, besucht am 22. Okt. 2025. Adresse: <http://geneontology.org/docs/ontology-documentation/>

- [68] W. Dankers, N. Davelaar, J. P. van Hamburg, J. van de Peppel, E. M. Colin und E. Lubberts, „Human Memory Th17 Cell Populations Change Into Anti-inflammatory Cells With Regulatory Capacity Upon Exposure to Active Vitamin D,“ *Frontiers in Immunology*, Jg. Volume 10 - 2019, 2019, ISSN: 1664-3224. DOI: [10.3389/fimmu.2019.01504](https://doi.org/10.3389/fimmu.2019.01504) Adresse: <https://www.frontiersin.org/journals/immunology/articles/10.3389/fimmu.2019.01504>
- [69] D. Woetzel u. a., „Identification of rheumatoid arthritis and osteoarthritis patients by transcriptome-based rule set generation,“ *Arthritis Research & Therapy*, Jg. 16, Nr. 2, R84, 1. Apr. 2014, ISSN: 1478-6354. DOI: [10.1186/ar4526](https://doi.org/10.1186/ar4526) Adresse: <https://doi.org/10.1186/ar4526>
- [70] M. A. A. Jansen, R. Spiering, I. S. Ludwig, W. van Eden, C. M. U. Hilkens und F. Broere, „Matured Tolerogenic Dendritic Cells Effectively Inhibit Autoantigen Specific CD4+ T Cells in a Murine Arthritis Model,“ *Frontiers in Immunology*, Jg. 10, 28. Aug. 2019, ISSN: 1664-3224. DOI: [10.3389/fimmu.2019.02068](https://doi.org/10.3389/fimmu.2019.02068) besucht am 30. Okt. 2025. Adresse: <https://www.frontiersin.org/journals/immunology/articles/10.3389/fimmu.2019.02068/full>
- [71] S. Wang u. a., „TolDC Restores the Balance of Th17/Treg via Aryl Hydrocarbon Receptor to Attenuate Colitis,“ *Inflammatory Bowel Diseases*, Jg. 30, Nr. 9, S. 1546–1555, 1. Sep. 2024, ISSN: 1536-4844. DOI: [10.1093/ibd/izae022](https://doi.org/10.1093/ibd/izae022) besucht am 30. Okt. 2025. Adresse: <https://doi.org/10.1093/ibd/izae022>
- [72] R. Volchenkov, M. Karlsen, R. Jonsson und S. Appel, „Type 1 Regulatory T Cells and Regulatory B Cells Induced by Tolerogenic Dendritic Cells,“ *Scandinavian Journal of Immunology*, Jg. 77, Nr. 4, S. 246–254, 2013, ISSN: 1365-3083. DOI: [10.1111/sji.12039](https://doi.org/10.1111/sji.12039) besucht am 30. Okt. 2025. Adresse: <https://onlinelibrary.wiley.com/doi/abs/10.1111/sji.12039>
- [73] F. Maleki, K. Ovens, I. McQuillan und A. J. Kusalik, „Size Matters: How Sample Size Affects the Reproducibility and Specificity of Gene Set Analysis,“ *Human Genomics*, Jg. 13, Nr. 1, S. 42, 22. Okt. 2019, ISSN: 1479-7364. DOI: [10.1186/s40246-019-0226-2](https://doi.org/10.1186/s40246-019-0226-2) besucht am 30. Okt. 2025. Adresse: <https://doi.org/10.1186/s40246-019-0226-2>
- [74] G. Altay, J. Zapardiel-Gonzalo und B. Peters, „RNA-seq preprocessing and sample size considerations for gene network inference,“ *bioRxiv: The Preprint Server for Biology*, S. 2023.01.02.522518, 3. Jan. 2023, ISSN: 2692-8205. DOI: [10.1101/2023.01.02.522518](https://doi.org/10.1101/2023.01.02.522518) PMID: [36711979](https://pubmed.ncbi.nlm.nih.gov/36711979/).
- [75] T. Hu u. a., „Metabolic regulation of the immune system in health and diseases: mechanisms and interventions,“ *Signal Transduction and Targeted Therapy*, Jg. 9, Nr. 1, S. 268, 9. Okt. 2024, ISSN: 2059-3635. DOI: [10.1038/s41392-024-01954-6](https://doi.org/10.1038/s41392-024-01954-6) Adresse: <https://doi.org/10.1038/s41392-024-01954-6>

- [76] E. Cribioli u. a., „Enforcing GLUT3 expression in CD8+ T cells improves fitness and tumor control by promoting glucose uptake and energy storage,“ *Frontiers in Immunology*, Jg. Volume 13 - 2022, 2022, ISSN: 1664-3224. DOI: [10.3389/fimmu.2022.976628](https://doi.org/10.3389/fimmu.2022.976628) Adresse: <https://www.frontiersin.org/journals/immunology/articles/10.3389/fimmu.2022.976628>
- [77] H. Chen, T. Yang, L. Zhu und Y. Zhao, „Cellular Metabolism on T-Cell Development and Function,“ *International Reviews of Immunology*, Jg. 34, Nr. 1, S. 19–33, 2015, PMID: 24708060. DOI: [10.3109/08830185.2014.902452](https://doi.org/10.3109/08830185.2014.902452) eprint: <https://doi.org/10.3109/08830185.2014.902452>. Adresse: <https://doi.org/10.3109/08830185.2014.902452>
- [78] P.-r. Gan, H. Wu, Y.-l. Zhu, Y. Shu und Y. Wei, „Glycolysis, a driving force of rheumatoid arthritis,“ *International Immunopharmacology*, Jg. 132, S. 111–113, 2024, ISSN: 1567-5769. DOI: <https://doi.org/10.1016/j.intimp.2024.111913> Adresse: <https://www.sciencedirect.com/science/article/pii/S1567576924004314>
- [79] J. Luo u. a., „A comparison of batch effect removal methods for enhancement of prediction performance using MAQC-II microarray gene expression data,“ *The Pharmacogenomics Journal*, Jg. 10, Nr. 4, S. 278–291, Aug. 2010, ISSN: 1473-1150. DOI: [10.1038/tpj.2010.57](https://doi.org/10.1038/tpj.2010.57) besucht am 31. Okt. 2025. Adresse: <https://www.nature.com/articles/tpj201057>
- [80] T. Sagendorf, *8.2 Over-Representation Analysis / Proteomics Data Analysis in R/Bioconductor*. besucht am 22. Okt. 2025. Adresse: <https://pnnl-comp-mass-spec.github.io/proteomics-data-analysis-tutorial/ora.html#ora-drawbacks>
- [81] J. Frost. „What is the Bonferroni Correction and How to Use It,“ *Statistics By Jim*, besucht am 16. Okt. 2025. Adresse: <https://statisticsbyjim.com/hypothesis-testing/bonferroni-correction/>
- [82] *Falscherkennungsrate*, in *Wikipedia*, 11. Feb. 2025. besucht am 29. Okt. 2025. Adresse: <https://de.wikipedia.org/w/index.php?title=Falscherkennungsrate&oldid=253237508>
- [83] S.-Y. Chen, Z. Feng und X. Yi, „A General Introduction to Adjustment for Multiple Comparisons,“ *Journal of Thoracic Disease*, Jg. 9, Nr. 6, S. 1725–1729, Juni 2017, ISSN: 2072-1439. DOI: [10.21037/jtd.2017.05.34](https://doi.org/10.21037/jtd.2017.05.34) PMID: 28740688. besucht am 29. Okt. 2025. Adresse: <https://pmc.ncbi.nlm.nih.gov/articles/PMC5506159/>
- [84] E. Ravasz, A. L. Somera, D. A. Mongru, Z. N. Oltvai und A. L. Barabási, „Hierarchical organization of modularity in metabolic networks,“ *Science (New York, N. Y.)*, Jg. 297, Nr. 5586, S. 1551–1555, 30. Aug. 2002, ISSN: 1095-9203. DOI: [10.1126/science.1073374](https://doi.org/10.1126/science.1073374) PMID: 12202830.

Abbildungsverzeichnis

1	Stammbaum der Leukozyten	4
2	Einfluss dendritischer Zellen auf die T-Zell-Differenzierung	5
3	Gesundes vs. RA-Gelenk	7
4	Vom Gen zum Genprodukt	8
5	Schematische Darstellung eines genregulatorischen Netzwerks	11
6	Verschiedene Kantenarten	11
7	Arten von Gennetzwerken	12
8	Graphen nach Kantenart und ihre Adjazenzmatrizen	13
9	Optimale Gradverteilung	14
10	Schematische Abbildung des BC3NET-Algorithmus	20
11	Klassische Modulsuche vs. DiffCoEx	25
12	DiffCoEx-Workflow	26
13	Differential-Koexpressionsszenarios	28
16	igraph-Darstellung des Test- (links) und des Kontrollnetzwerks (rechts) .	34
17	Beobachtete Gradverteilung	34
18	Erreichte R^2 -Werte für verschiedene mögliche Thresholds	35
19	Analyse des Einflusses der Schritthöhe	36
20	Dendrogramm mit Modulzuteilung	38
21	Permutationsergebnisse	39
22	Reifung dendritischer Zellen	42

Tabellenverzeichnis

1	Definitionen zentraler Begriffe der Netzwerkanalyse.	10
2	Verwendete R-Pakete und deren Versionen.	19
3	GO-Kategorien und ihre Beschreibungen.	30
4	Vergleich der Netzwerkeigenschaften von netTest und netControl.	35
5	Übersicht der identifizierten Module mit enthaltenen Genen.	37
6	GO-Anreicherungsanalyse der identifizierten Module.	40

Codeverzeichnis

- 3.1 Berechnung der Netzwerke mit BC3NET 23
- 3.2 Die Wahl von beta1 23
- 3.3 Visualisierung der Netzwerke 24
- 3.4 Functional Enrichment 31

Anhang

Over-Representation Analysis (ORA)

Trotz ihrer weiten Verbreitung ist ORA mit mehreren konzeptionellen und statistischen Schwächen behaftet und wird daher in der Literatur zunehmend kritisch betrachtet [66], [80]. Ein zentrales Problem liegt in der **Abhängigkeit von der gewählten Signifikanzschwelle**: Bereits kleine Änderungen im Schwellenwert (p-Wert) oder in der Methode zur Mehrfachtestkorrektur können zu stark unterschiedlichen Ergebnissen führen. Zudem berücksichtigt ORA nicht die **Richtung der Expressionsänderung**; es wird nicht unterschieden, ob Gene innerhalb eines Sets überwiegend hoch- oder herunterreguliert sind. Eine Aufteilung der Gene nach Expressionsrichtung und anschliessende getrennte Analyse wäre zwar rechnerisch möglich, ist aber methodisch problematisch und kann zu Fehlinterpretationen führen. Ein weiterer Nachteil besteht darin, dass ORA **bei kleinen Genmodulen instabil** ist. Wenn beispielsweise nur sehr wenige Gene als “interessant” klassifiziert werden, können minimale Änderungen in der Anzahl dieser Gene die Signifikanz einzelner Anreicherungen drastisch verändern. Das führt dazu, dass scheinbar signifikante Ergebnisse häufig nicht robust sind. Schliesslich setzt ORA voraus, dass jedes Gen nur einmal im Datensatz vorkommt. Doppelte Einträge oder redundante Zuordnungen – etwa wenn mehrere Proteine demselben Gen zugeordnet werden – können zu einer **künstlichen Überrepräsentation** führen. Aufgrund dieser Einschränkungen wird ORA in aktuellen Studien nicht als optimale Methode nach einer differentiellen Expressionsanalyse empfohlen. Methoden wie die **Gene Set Enrichment Analysis (GSEA)**, die auf kontinuierlichen Rangstatistiken beruhen und sowohl Effektgrösse als auch Richtung der Regulation berücksichtigen, bieten hier eine methodisch überlegene Alternative.

Begründung der Estimatorwahl “Spearman” für BC3NET

Die Wahl der **Spearman-Rangkorrelation** für die Analyse der Gen-Koexpression in dieser Arbeit stützt sich auf die vergleichende Studie von Kumari et al. (2012). Die Autoren untersuchten acht statistische Methoden und zeigten, dass Spearman eine der leistungsstärksten ist, um biologisch sinnvolle Zusammenhänge in Genexpressionsdaten aufzudecken.

Die Studie belegt dies anhand von zwei zentralen Kriterien:

1. **Empirische Leistung**: Spearman identifizierte äusserst effektiv Gene, die zu denselben biologischen Signalwegen gehören. Ebenso war die Methode sehr

erfolgreich bei der Konstruktion von GRNs. In allen Tests schnitt sie durchweg besser ab als die weitverbreitete Pearson-Korrelation.

2. **Theoretische Eignung:** Der entscheidende Vorteil von Spearman ist seine Eigenschaft als nicht-parametrische, rangbasierte Methode. Das bedeutet, sie verwendet die Rangfolge der Genexpressionswerte anstelle der Absolutwerte. Dies macht sie unempfindlich gegenüber Ausreissern (outliers) und setzt keine Normalverteilung der Daten voraus.

Neben der Leistungsstärke wurde auch die **Berechnungsdauer** berücksichtigt: Im Vergleich zu vielen anderen Methoden, einschliesslich der in der Studie vorgeschlagenen Alternativen, ist Spearman rechengünstig.

Korrektur für multiples Testen

Wenn im Rahmen einer Studie **mehrere statistische Hypothesentests** durchgeführt werden, steigt das Risiko für Zufallsbefunde (α -Fehler-Kumulierung) [81]. Um dies zu kontrollieren, werden zwei Masse unterschieden:

1. Die **Family-Wise Error Rate (FWER)** ist die Wahrscheinlichkeit, mindestens einen falsch-positiven Befund (Fehler 1. Art) in der gesamten Test-Familie zu erhalten. Sie ist ein strenges Mass, um jeglichen Fehlalarm zu vermeiden.
2. Die **False Discovery Rate (FDR)** bezeichnet den erwarteten Anteil der falsch-positiven Ergebnisse an allen tatsächlich als signifikant ("positiv") erklärten Ergebnissen. Sie erlaubt einzelne Fehler, solange der Grossteil der Entdeckungen korrekt ist [82].

Die Bonferroni-Korrektur

Die Bonferroni-Korrektur ist eine Methode zur FWER-Kontrolle [81]. Die Korrektur wird durchgeführt, indem das ursprüngliche Signifikanzniveau durch die Anzahl der durchgeführten Tests dividiert wird:

$$\alpha_{corr} = \alpha/n$$

Ein Ergebnis wird nur dann als statistisch signifikant betrachtet, wenn sein p-Wert kleiner oder gleich diesem neuen, strengeren Wert von α_{corr} ist. Der Hauptnachteil der Bonferroni-Korrektur ist, dass sie **sehr konservativ** ist, insbesondere bei einer grossen Anzahl von Tests. Indem sie das Kriterium für Signifikanz so stark verschärft, reduziert sie die statistische Power. Das bedeutet, die Wahrscheinlichkeit, einen tatsächlich existierenden Effekt zu übersehen (ein Fehler 2. Art oder falsch-negatives Ergebnis), steigt an.

Die Benjamini-Hochberg-Korrektur

Die Benjamini-Hochberg-Korrektur (BH-Korrektur) ist ein Verfahren zur FDR-Kontrolle [83]. Der Prozess der BH-Korrektur erfolgt in mehreren Schritten:

1. Sortierung der p-Werte: Zunächst werden die p-Werte aller getesteten Hypothesen in aufsteigender Reihenfolge geordnet.
2. Berechnung des Schwellenwerts: Für jeden p-Wert wird ein kritischer Schwellenwert q berechnet, der in der Form $q = k/m \cdot Q$ definiert wird, wobei k die Position des jeweiligen p-Werts in der sortierten Liste, m die Gesamtzahl der Tests und Q die gewünschte maximale FDR ist.
3. Abweisung der Nullhypothesen: Alle Nullhypothesen mit einem p-Wert, der kleiner oder gleich dem berechneten Schwellenwert ist, werden abgelehnt.

Die BH-Korrektur ermöglicht eine **flexiblere Kontrolle** der Fehlerquote, was insbesondere bei einer grossen Anzahl von Tests von Vorteil ist. Durch diese Methode wird die Wahrscheinlichkeit von falsch positiven Ergebnissen reduziert, ohne die Teststärke drastisch zu beeinträchtigen. Daher ist die BH-Korrektur besonders in Studien mit vielen simultan getesteten Hypothesen von Bedeutung.

Der Topological Overlap Measure (TOM)

Mathematische Grundlagen

Der Topological Overlap Measure (TOM) beschreibt, wie ähnlich oder miteinander verbunden zwei Knoten eines Netzwerks sind; nicht nur auf direktem Wege durch eine Kante, sondern auch **indirekt** durch gemeinsame Nachbarn [20]. Er kann mit folgender Formel berechnet werden:

$$\omega_{ij} = \frac{l_{ij} + a_{ij}}{\min(k_i, k_j) + 1 - a_{ij}}$$

$l_{ij} = \sum_u a_{iu}a_{ju}$ entspricht der Anzahl Knoten u , die sowohl mit i als auch mit j verbunden sind. $k_i = \sum_u a_{iu}$ beschreibt die Anzahl Nachbarn (Grad) von i . a_{ij} stellt den Koexpressionswert da. Es entsteht ein nicht-gewichtetes TOM ($w_{ij} = 0, 1$), wenn a_{ij} nur die Werte 0 und 1 annehmen kann [84]. Falls allerdings $0 \leq a_{ij} \leq 1$, liegt auch ω_{ij} im Intervall $[0; 1]$. Ist $\omega_{ij} = 1$, dann besitzen die zwei Knoten i und j eine perfekte topologische Überschneidung: Alle Nachbarn des Knotens i , das die wenigsten Kanten besitzt, sind also mit dem anderen Knoten j verbunden. Ausserdem sind i und j sind untereinander direkt verbunden. Im Gegensatz bedeutet $\omega_{ij} = 0$, dass i und j nicht direkt verbunden sind und keine gemeinsamen Nachbarn besitzen. In der Praxis wird häufig mit Dissimilarität gehandelt. Um das Ähnlichkeitsmass TOM umzuwandeln, kann es von 1 subtrahiert werden:

$$d_{ij}^\omega = 1 - \omega_{ij}$$

Praktische Umsetzung

```
1 dissTOM <- TOMdist((AdjDiff)^(beta1/2))
```

Die verwendete Funktion `TOMdist()` berechnet zunächst das TOM und wandelte dieses anschliessend in ein Dissimilaritätsmass um. Um eine skalenfreie Topologie (Kap.

2.3.4) zu erreichen, wurde der Parameter β_{a1} empirisch gesetzt. Diese Entscheidung wurde in Kapitel 5 ausführlich diskutiert.